INSTITUTO SUPERIOR TECNOLÓGICO UNIVERSITARIO RUMIÑAHUI

ESCUELA DE POSGRADOS

MAESTRÍA TECNOLÓGICA EN HERRAMIENTAS DIGITALES PARA EL ANÁLISIS DE DATOS E INTELIGENCIA ARTIFICIAL

Trabajo de titulación previo a la obtención del Título de Magíster Tecnológico en Herramientas Digitales para el Análisis de Datos e Inteligencia Artificial

Tema:

Generación asistida de fragmentos de ocho compases de contrapunto barroco para piano mediante LSTM con verificación de reglas contrapuntísticas

Autor:

Ernesto Alcívar López

Director:

Ing. Juan Carlos Minango Negrete

Ecuador, 2026

©2024 Tecnológico Universitario Rumiñahui

Sangolquí – Ecuador

Autor:



Alcívar López Ernesto

Título a obtener: Maestría Tecnológica en herramientas digitales para el analisis de datos e inteligencia artificial

Matriz: Sangolquí -Ecuador

Correo electrónico:

ernesto.alcivar@ister.edu.ec

Dirigido por:



Minango Negrete Juan Carlos

Título: PhD.

Matriz: Sangolquí -Ecuador

Correo electrónico:

juancarlos.minango@ister.edu.ec

Todos los derechos reservados

Queda prohibida, salvo excepción prevista en la Ley, cualquier forma de reproducción, distribución, comunicación pública y transformación de esta obra para fines comerciales, sin contar con autorización de los titulares de propiedad intelectual. La infracción de los derechos mencionados puede ser constitutiva de delito contra la propiedad intelectual. Se permite la libre difusión de este texto con fines académicos investigativos por cualquier medio, con la debida notificación a los autores.

@2026 Tecnológico Universitario Rumiñahui

Sangolquí – Ecuador

ALCÍVAR LÓPEZ ERNESTO

APROBACIÓN DEL DIRECTOR DEL TRABAJO TITULACIÓn

Sangolquí, 2 de cotubre del 2026

MSc. Vinicio Ramón
Director de Posgrados
Instituto Superior Tecnológico Universitario Rumiñahui
Presente

De mi consideración:

Me permito comunicar que, en calidad de director del presente Trabajo de Titulación denominado: " GENERACIÓN ASISTIDA DE OCHO COMPASES DE CONTRAPUNTO BARRÓCO PARA PIANO MEDIANTE LSTM CON VERIFICACIÓN DE REGLAS CONTRAPUNTÍSTICAS" realizado por ERNESTO ALCÍVAR LÓPEZ, ha sido orientado y revisado durante su ejecución, así mismo ha sido verificado a través de la herramienta de similitud académica institucional, y cuenta con un porcentaje de coincidencia aceptable. En virtud de ello, y por considerar que el mismo cumple con todos los parámetros establecidos por la institución, doy mi aprobación a fin de continuar con el proceso académico correspondiente.

Particular que comunico para los fines pertinentes.
Atentamente,

Firmado electrónicamente por:
JUAN CARLOS MINANGO NEGRETE

PhD. Juan Carlos Minango Negrete
Director del Trabajo de Titulación
C.I.: 171604244-3
Correo electrónico: juancarlos.minango@ister.edu.ec

CARTA DE CESIÓN DE DERECHOS DEL TRABAJO DE TITULACIÓN

Sangolquí, 2 de octubre del 2026

MSc. Vinicio Ramón
Director de Posgrados
Instituto Superior Tecnológico Universitario Rumiñahui
Presente

De mi consideración:

Por medio de la presente, yo, ERNESTO ALCÍVAR LÓPEZ, declaro y acepto en forma expresa lo siguiente: ser autor del trabajo de titulación denominado " GENERACIÓN ASISTIDA DE OCHO COMPASES DE CONTRAPUNTO BARRÓCO PARA PIANO MEDIANTE LSTM CON VERIFICACIÓN DE REGLAS CONTRAPUNTÍSTICAS", de la Maestría Tecnológica en Herramientas Digitales para el Análisis de Datos e Inteligencia Artificial; manifiesto mi voluntad de ceder al Instituto Superior Tecnológico Universitario Rumiñahui los derechos de reproducción, distribución y publicación de dicho trabajo de titulación, en cualquier formato y medio, con fines académicos y de investigación.

Esta cesión se otorga de manera no exclusiva y por un periodo indeterminado. Sin embargo, conservo los derechos morales sobre mi obra.
En fe de lo cual, firmo la presente.
Atentamente,

Ernesto Alcívar López
C.I.: 1716684509

FORMULARIO PARA ENTREGA DEL TRABAJO DE TITULACIÓN EN BIBLIOTECA DEL INSTITUTO SUPERIOR TECNOLÓGICO UNIVERSITARIO RUMIÑAHUI

MAESTRÍA TECNOLÓGICA: MAESTRÍA TECNOLÓGICA EN HERRAMIENTAS DIGITALES PARA EL ANÁLISIS DE DATOS E INTELIGENCIA ARTIFICIAL

AUTOR:
Ernesto Alcívar López

TUTOR:
PhD. Juan Carlos Minango Negrete

CONTACTO ESTUDIANTE:
+593 96 054 1969

CORREO ELECTRÓNICO:
ernesto.alcivar@ister.edu.ec

TEMA:
" GENERACIÓN ASISTIDA DE OCHO COMPASES DE CONTRAPUNTO BARRÓCO PARA PIANO MEDIANTE LSTM CON VERIFICACIÓN DE REGLAS CONTRAPUNTÍSTICAS "

SOLICITUD DE PUBLICACIÓN DEL TRABAJO DE TITULACIÓN

Sangolquí, 2 de octubre del 2026

MSc. Vinicio Ramón
Director de Posgrados
Instituto Superior Tecnológico Universitario Rumiñahui
Presente

De mi consideración:

A través del presente me permito aceptar la publicación del trabajo de titulación denominado: " GENERACIÓN ASISTIDA DE OCHO COMPASES DE CONTRAPUNTO BARRÓCO PARA PIANO MEDIANTE LSTM CON VERIFICACIÓN DE REGLAS CONTRAPUNTÍSTICAS." del estudiante: Ernesto Alcívar López, con documento de identificación No 1716684509, estudiante de la Maestría Tecnológica en Herramientas Digitales para el Análisis de Datos e Inteligencia Artificial.

El trabajo ha sido revisado las similitudes en el software “TURNITING” y cuenta con un porcentaje máximo de 15%; motivo por el cual, el Trabajo de titulación es publicable.

Atentamente,

Ernesto Alcívar López
C.I.: 1716684509

Dedicatoria

A mi familia, por su apoyo incondicional.

Agradecimiento

A mi director, Ing. Juan Carlos Minango Negrete, por su guía y paciencia.

Resumen

Esta tesis responde a la pregunta de si la verificación algorítmica de reglas contrapuntísticas mejora la generación de contrapunto barroco respecto de un enfoque puramente end-to-end, mediante un sistema híbrido de generación asistida de fragmentos de ocho compases para piano. El pipeline combina un modelo LSTM con planificación formal, control tonal, retención motívica y evaluación artística multidimensional, y evalúa cada fragmento con un validador basado en las reglas de Fux. El estudio experimental se ejecutó sobre un corpus de **358** pares de voces de Bach (15 Invenciones + 45 pares de Sinfonías + 213 pares del Clave Bien Temperado + 85 pares del Arte de la Fuga), aumentado a **6.086** secuencias tokenizadas (vocabulario REMI de 391 tokens). El modelo LSTM ampliado (**1.44M** parámetros) se entrenó en 26 épocas con *early stopping*. Los experimentos comparan el pipeline contra una línea base end-to-end sobre el mismo modelo ($N = 30$ ejecuciones por grupo); los resultados oficiales se consolidan en una única tabla canónica (Capítulo 5). La integración plan–validador eleva la tasa de aceptación según los criterios Fux (consonancia $\geq$75 %, movimiento contrario $\geq$40 %, sin quintas u octavas paralelas) del 0 % (0/30) al 16.7 % (5/30), mejora sustancialmente el movimiento contrario y consigue que las 30/30 ejecuciones superen el gate artístico (ArtisticScore $\geq$0.6). No obstante, la generación end-to-end sin validación no alcanza los umbrales, la consonancia no mejora respecto del baseline y los fragmentos resultan mucho más escasos que la referencia de Bach, con cierres cadenciales débiles. La evaluación computacional se complementa con un estudio piloto de escucha ciega ($N = 3$ docentes especialistas, 15 estímulos): los evaluadores distinguieron el 100 % de las muestras generadas como creaciones artificiales con certeza máxima y coincidieron perceptivamente con el diagnóstico cuantitativo de pobreza textural y cadencias truncadas. El trabajo incluye además un análisis de sensibilidad de los pesos artísticos y un diagnóstico del validador sobre el corpus de Bach. La implementación es reproducible: código, configuraciones y semillas están registrados en el repositorio del proyecto.

Palabras clave: generación musical, contrapunto barroco, LSTM, validación contrapuntística, musicología computacional.

Abstract

This thesis addresses the question of whether algorithmic verification of contrapuntal rules improves Baroque counterpoint generation relative to a purely end-to-end approach, through a hybrid system for the assisted generation of eight-measure piano fragments. The pipeline combines an LSTM model with formal planning, tonal control, motivic retention, and multidimensional artistic evaluation, and assesses each fragment with a validator based on Fux's rules. The experimental study was run on a corpus of **358** pairs of Bach voices (15 Inventions + 45 Sinfonia pairs + 213 pairs from The Well-Tempered Clavier + 85 pairs from The Art of Fugue), augmented to **6,086** tokenized sequences (REMI vocabulary of 391 tokens). The extended LSTM model (**1.44M** parameters) was trained for 26 epochs with *early stopping*. The experiments compare the pipeline against an end-to-end baseline on the same model ($N = 30$ runs per group); the official results are consolidated in a single canonical table (Chapter 5). The plan–validator integration raises the acceptance rate under the Fux criteria (consonance $\geq$75%, contrary motion $\geq$40%, no parallel fifths or octaves) from 0% (0/30) to 16.7% (5/30), substantially improves contrary motion, and achieves 30/30 runs passing the artistic gate (ArtisticScore $\geq$0.6). Nevertheless, end-to-end generation without validation does not reach the thresholds, consonance does not improve over the baseline, and the fragments are much sparser than the Bach reference, with weak cadential closures. The computational evaluation is complemented by a pilot blind-listening study ($N = 3$ specialist instructors, 15 stimuli): the evaluators distinguished 100% of the generated samples as artificial creations with maximum certainty and perceptually agreed with the quantitative diagnosis of textural poverty and truncated cadences. The work also includes a sensitivity analysis of the artistic weights and a validator diagnostic on the Bach corpus. The implementation is reproducible: code, configurations, and seeds are recorded in the project repository.

Keywords: musical generation, Baroque counterpoint, LSTM, contrapuntal validation, computational musicology.

Índice general

Problema de Investigación y Objetivos **1**

Problema de Investigación 1

Objetivo General 2

Objetivos Específicos 2

1. Estado del Arte **4**

1.1. Fundamentos del Contrapunto Barroco 4

1.2. Inteligencia Artificial para la Composición Musical 5

1.2.1. Enfoque Basado en Reglas y Gramáticas Formales 5

1.2.2. Enfoque Basado en Aprendizaje Neuronal 5

1.3. Modelos Generativos para Contrapunto y Música Polifónica 6

1.3.1. DeepBach 6

1.3.2. BachDuet 6

1.3.3. Modelos Secuenciales para Contrapunto a Dos Voces 7

1.3.4. Modelos Recientes y Controlables (2024–2025) 7

1.3.5. Síntesis de la Brecha 8

1.4. Aprendizaje con Datos Limitados (*Few-Shot Learning*) en Música 8

1.4.1. Aumentación Simbólica 9

1.4.2. Regularización para Datos Limitados 9

1.5. Representación Musical Simbólica y Herramientas Computacionales 10

1.5.1. Formatos de Representación 10
1.5.2. Herramientas Computacionales 11
1.6. Brecha de Investigación y Aportación del Proyecto 11

2. Metodología Experimental **13**
2.1. Enfoque y Diseño de Investigación 13
2.2. Población y Muestra 14
2.2.1. Población 14
2.2.2. Corpus de entrenamiento 14
2.2.3. Conversión a pares de voces 16
2.2.4. División Train/Validation 17
2.3. Hipótesis de Investigación 17
2.4. Técnicas e Instrumentos de Recolección de Datos 19
2.4.1. Instrumento 1: Algoritmo Validador de Contrapunto 19
2.4.2. Instrumento 2: Prueba de Escucha Ciega (estudio piloto aplicado) . . 20
2.5. Procedimiento Experimental 20
2.5.1. Preprocesamiento 20
2.5.2. Arquitectura del Modelo 20
2.5.3. Generación de Contrapunto para Piano (2 Voces) 23
2.5.4. Pipeline mejorado de generación de fragmentos de ocho compases . . 24
2.5.5. Protocolo experimental ampliado 27
2.5.6. Análisis estadístico 29
2.5.7. Validación 29
2.6. Técnicas de Análisis de Datos 30
2.7. Materiales y Recursos 30
2.7.1. Hardware 30
2.7.2. Software 31
2.7.3. Archivos del proyecto 31

2.7.4. Reproducibilidad experimental 33
2.8. Consideraciones Éticas 33

3. Alcance y Delimitación del Proyecto **35**
3.1. Delimitación del Ámbito de Intervención 35
3.2. Límites del Estudio 35
3.3. Productos Esperados 38
3.4. Aspectos a Desarrollar durante la UIC 39

4. Diseño de Instrumentos y Protocolo de Validación **40**
4.1. Instrumentos de Recolección y Evaluación de Información 40
4.1.1. Instrumento 1: Algoritmo Validador de Reglas Contrapuntísticas (Cuantitativo) 40
4.1.2. Instrumento 2: Prueba de Escucha Ciega (Cualitativo) — Estudio Piloto 43
4.2. Matriz de Operacionalización de Variables 44
4.3. Protocolo de Aplicación de Instrumentos 45
4.3.1. Fase 1: Validación Computacional (Automática) 45
4.3.2. Fase 2: Validación con Expertos (Estudio Piloto) 45
4.3.3. Fase 3: Análisis y Reporte Integrado 45

5. Resultados **47**
5.1. Resultados del Entrenamiento del Modelo LSTM 47
5.1.1. Evolución del entrenamiento 47
5.1.2. Corrección del pipeline de tokenización 50
5.1.3. Corpus de entrenamiento y arquitectura del modelo 50
5.1.4. Generación medida por medida con validación 51
5.2. Resultados del Pipeline Mejorado (Fragmentos de Ocho Compases) 52
5.2.1. Análisis de sensibilidad del ArtisticScore 56
5.3. Discusión científica de los resultados 62

5.3.1. Paradoja de la consonancia y las disonancias no resueltas 63
5.4. Resultados de la Validación Cuantitativa 65
5.4.1. Línea base: corpus Bach (358 pares de voces) 65
5.4.2. Diagnóstico del validador sobre el corpus Bach 66
5.4.3. Evaluación exploratoria end-to-end bivocal (piloto N=1) 69
5.4.4. Comparación con la línea base de Bach 72
5.4.5. Prueba de significancia estadística 72
5.5. Distribución de intervalos del corpus Bach 73
5.6. Análisis musical de los fragmentos generados 76
5.6.1. Lectura del fragmento mejor aceptado (s1111) 77
5.6.2. Fragmentos mediano y problemático (s314, s13579) 78
5.6.3. Comparación con la referencia de Bach y conclusiones del análisis . . 80
5.6.4. Contribución incremental de los módulos del pipeline 80
5.6.5. Densidad y textura musical 82
5.6.6. Prueba de escucha ciega (estudio piloto con especialistas) 83
5.7. Limitaciones del validador 86
5.8. Lecciones sobre representación musical para contrapunto polifónico 88
5.9. Análisis Crítico de los Resultados 89
5.10. Síntesis de Resultados 90

6. Conclusiones y Recomendaciones **92**

6.1. Conclusiones 92
6.1.1. Sobre el cumplimiento de objetivos 92
6.1.2. Sobre las preguntas de investigación 94
6.1.3. Contribuciones de la investigación 94
6.1.4. Limitaciones 96
6.1.5. Amenazas a la validez 98
6.2. Recomendaciones 99

6.2.1. Líneas futuras de investigación 99
6.2.2. Recomendaciones prácticas 100
6.3. Reflexión Final 100

A. Ejemplos de Salidas Generadas **102**
A.1. Ejemplo de Melodía Generada por LSTM 102
A.2. Ejemplo de Contrapunto Generado (Pipeline Completo) 102
A.3. Distribución de Scores del Lote de Generación 103
A.4. Plan de Prueba de Escucha Ciega 103

B. Resultados Experimentales Ampliados **105**
B.1. Ejecuciones Individuales del Pipeline Mejorado 105
B.2. Línea Base (baseline) 106

Referencias Bibliográficas **108**

Índice de figuras

2.1. Arquitectura del modelo LSTM ampliado (`modelo_epoca_10.keras`, 1446215 parámetros entrenables). La entrada es una secuencia de tokens REMI intercalados (una voz por token, alternando Program_0 y Program_1). Tres capas LSTM de 256 unidades capturan dependencias temporales de largo alcance. La salida predice el siguiente token del vocabulario completo. 21

2.2. Diagrama de flujo del pipeline completo: desde el corpus MIDI original hasta la generación de compases de contrapunto para piano con validación de reglas contrapuntísticas y retroalimentación. 23

2.3. Diagrama del pipeline mejorado: el `GenerationController` orquesta el plan formal/tonal, la generación multi-candidato con reintentos dirigidos, la validación contrapuntística por compás y el gating por ventanas, y selecciona por ArtisticScore el fragmento integrado de ocho compases 26

5.1. Evolución de la pérdida (loss) durante el entrenamiento. La línea vertical marca el mejor `val_loss` en la época 10. 48

5.2. Evolución de la exactitud durante el entrenamiento. 48

5.3. Escalón de tasa de aprendizaje por `ReduceLROnPlateau`. Se observan dos reducciones desde 0.001 hasta 0.00025. 49

5.4. Panel del pipeline mejorado (ejecución run5): curva de tensión por compás (arriba), ArtisticScore por compás con la línea del puntaje final (centro) y puntuación de ventana acumulada (abajo). El gate de ventanas mantiene la coherencia entre compases a lo largo del fragmento. 58
5.5. Comparación de consonancia y movimiento contrario entre el baseline ($N = 30$) y el pipeline mejorado ($N = 30$). La barra de error indica una desviación estándar. 58
5.6. Distribución del ArtisticScore en el experimento ampliado ($N = 30$). La línea vertical marca el umbral de aceptación ($\geq$0.6). 59
5.7. Aceptación por semilla en el pipeline mejorado ($N = 30$). Verde: aceptado por gate artístico; rojo: rechazado. 59
5.8. Distribución de consonancia: baseline ($N = 30$) vs pipeline mejorado ($N = 30$). La línea vertical marca el umbral del 75 %. 59
5.9. Distribución de movimiento contrario: baseline ($N = 30$) vs pipeline mejorado ($N = 30$). La línea vertical marca el umbral del 40 %. 60
5.10. Diagrama de dispersión: consonancia vs movimiento contrario. Círculos rojos: baseline ($N = 30$); diamantes azules: pipeline mejorado ($N = 30$). 60
5.11. Distribución de consonancia (izquierda) y movimiento contrario (derecha): corpus Bach ($N = 358$), pipeline mejorado ($N = 30$) y baseline ($N = 30$). Líneas discontinuas: umbrales pedagógicos (0.75 / 0.40); líneas punteadas: percentiles P25 del corpus. El baseline se concentra en 0 % en ambas métricas; el pipeline mejorado se acerca a la masa central de Bach en consonancia y la supera en movimiento contrario. 68
5.12. Distribución de la razón de consonancia: corpus Bach ($N = 358$) vs generado. La línea vertical marca el umbral del 75 %. Los resultados del protocolo ampliado se reportan en la Tabla 5.3a y en las figuras de distribución del experimento $N = 30$. 69

5.13. Distribución del movimiento contrario: corpus Bach ($N = 358$) vs generado. El umbral del 40 % se indica con línea vertical. Los resultados del protocolo ampliado se reportan en la Tabla 5.3a y en las figuras de distribución del experimento $N = 30$. 69
5.14. Distribución del puntaje compuesto de las muestras generadas. Los puntajes van de 75 a 95, con mediana de 85.0. 70
5.15. Diagrama de dispersión: razón de consonancia vs movimiento contrario. Los diamantes azules representan las 15 invenciones originales de Bach. Los círculos verdes y rojos son muestras generadas (verde = pasan ambos umbrales). . 70
5.16. Distribución de intervalos armónicos en el corpus de Bach. Las barras azules son consonancias, rojas disonancias, naranja P4 (no clasificada) y grises intervalos perfectos. 74
5.17. Fragmento generado de la semilla 1111 (mejor ejecución aceptada por la validación Fux): contrapunto barroco a dos voces con anotación del plan formal. 77
5.18. Partitura anotada del fragmento s314 (ArtisticScore 0.734): material casi exclusivo en voz aguda; final B4–C4 sin resolución V–I. 79
5.19. Partitura anotada del fragmento s13579 (ArtisticScore 0.696): tritono B3–E♭3 sin resolución; compás final vacío (cadencia fallida). 79

Índice de tablas

2.1. Fases de la investigación 14
2.2. Corpus de entrenamiento: 358 pares de voces de Bach 15
2.3. Detalle de la conversión a pares de voces 16
2.4. Parámetros del modelo LSTM ampliado (`modelo_epoca_10.keras`) 22
2.5. Pesos del ArtisticScore (config/generation.yaml) 27

3.1. Productos esperados del proyecto 38

4.1. Variables del algoritmo validador 41
4.2. Matriz de operacionalización de variables 44

5.1. Evolución del entrenamiento del modelo LSTM 49
5.2. Generación medida por medida: mejor ejecución aceptada del experimento $N = 30$ (semilla 1111) frente al corpus Bach 51
5.3a. (a) Tabla canónica de resultados — métricas contrapuntísticas y aceptación Fux. Fuente de verdad de toda la tesis: las métricas se reportan una sola vez aquí y se citan en los demás capítulos sin repetirse. Bach: corpus completo ($N = 358$ pares de voces). Baseline y Mejorado: experimento $N = 30$ por grupo (modelo único, epoch 10). 53
5.3b. (b) Tabla canónica de resultados — coherencia musical y ArtisticScore (solo pipeline mejorado, $N = 30$). 54

5.5. Pipeline mejorado (n30_20260820): estadísticas agregadas con intervalos de confianza bootstrap al 95 % (N=30 ejecuciones, una por semilla). Consonancia/movimiento contrario medidos sobre MIDI exportado con el mismo instrumento que el baseline (N=30). 54
5.6. Comparación baseline vs pipeline mejorado. Criterios Fux medidos sobre MIDI exportado (mismo instrumento). Prueba U de Mann-Whitney (una cola, mejorado > baseline) y d de Cohen. IC95 % bootstrap entre corchetes. 56
5.7. Sensibilidad del ArtisticScore ante cambios de pesos (N=30 ejecuciones). "Cambia mejor" indica si la semilla de mayor puntaje difiere del esquema actual; τ es la correlación de Kendall entre el ranking del esquema y el del esquema actual. 57
5.8. Métricas del corpus Bach (358 pares de voces) 65
5.9. Causas de rechazo del corpus Bach (N=358 pares de voces) bajo dos conjuntos de umbrales. Pedagógicos: consonancia $\geq$0.75, movimiento contrario $\geq$0.40, sin paralelismos. Recalibrados: percentiles del corpus (consonancia P25=0.6948, movimiento contrario P25=0.4329, quintas P75=0). El validador no es un filtro que defina "ser bachiano": casi la mitad de Bach no supera los criterios pedagógicos. 66
5.10. Análisis de sensibilidad de los umbrales del validador. Tasa de piezas aprobadas sobre el corpus Bach (N=358), el pipeline mejorado (N=30) y el baseline (N=30), variando un umbral a la vez respecto a la configuración pedagógica (0.75 / 0.40 / 0). El grid completo queda en `threshold_sensitivity.csv` (results/validation). 67
5.11. Evaluación exploratoria end-to-end bivocal (piloto N=1; no constituye el resultado oficial) 71

5.12. Comparación exploratoria basada en el piloto N=1 (una única muestra end-to-end de la etapa temprana; no constituye comparación oficial). La comparación oficial baseline vs pipeline mejorado se reporta en la Tabla 5.3a. 72
5.13. Distribución de intervalos armónicos en el corpus Bach 75
5.14. Resumen del análisis musical de los fragmentos 76
5.15. Pipeline mejorado por configurácion (N=3 semillas por config). Valor central: media; entre paréntesis, desviación estándar. 81
5.16. Densidad y textura musical de los fragmentos generados frente a la referencia bachiana (8 compases por pieza). 82
5.17. Prueba de escucha ciega (piloto, $N = 3$ especialistas): discriminación binaria por estímulo ($N = 15$). 84
5.18. Valoraciones en escala Likert 1–5 por grupo de estímulos (Media ± DE [Mediana], $N = 3$ especialistas). 85

6.1. Respuestas a las preguntas de investigación 94

A.1. Métricas de eval_086.mid 103
A.2. Estadísticas del score total (lote de generación, N=30) 103

B.1. Ejecuciones individuales del pipeline mejorado (N=30; una ejecución por semilla). Consonancia y movimiento contrario medidos sobre MIDI (mismo instrumento que baseline). 105
B.2. Baseline (generación end-to-end bivocal, perfil controlled): estadísticas agregadas con IC95 % bootstrap (N=30 ejecuciones, una por semilla). 107

Problema de Investigación y Objetivos

Problema de Investigación

No existe, a la fecha, un pipeline de entrenamiento de redes neuronales capaz de generar contrapunto imitativo barroco a dos voces que respete simultáneamente las reglas armónicas verticales y la coherencia formal horizontal propias del estilo. En particular, se identifican tres problemas no resueltos:

1. **Inexistencia de modelos *few-shot* para contrapunto polifónico.** Los modelos generativos secuenciales existentes no logran aprender patrones contrapuntísticos complejos a partir de conjuntos de datos extremadamente pequeños como el corpus de las 15 Invenciones de Bach (apenas ∼3.000 compases), ampliado a 30 piezas con la inclusión de las 15 Sinfonías a tres voces (BWV 787–801) y, en la iteración vigente, con la incorporación del Clave Bien Temperado (BWV 846–893) y el Arte de la Fuga (BWV 1080), alcanzando 358 pares de voces, lo que deriva en sobreajuste o en una capacidad limitada de generalizar el estilo.

2. **Pérdida de coherencia formal en secuencias largas.** Las arquitecturas autorregresivas estándar no mantienen la relación de imitación sujeto-respuesta más allá de unos pocos compases, generando *output* musical que carece de la estructura dialógica característica del contrapunto barroco.

3. **Ausencia de un marco de validación cuantitativo para contrapunto generado**

y de un sistema híbrido que combine generación neuronal con verificación de reglas. No existe un estándar ni un algoritmo validado que evalúe sistemáticamente la corrección contrapuntística del *output* generado por modelos de inteligencia artificial musical, ni un pipeline documentado que integre generación autoregresiva con retroalimentación de reglas para verificar la validez armónica del resultado.

Objetivo General

Diseñar, entrenar y evaluar un sistema híbrido de generación asistida de fragmentos de ocho compases de contrapunto barroco a dos voces para piano que combine modelos de redes neuronales secuenciales (LSTM) con aumentación simbólica para aprendizaje con datos limitados, acoplado a un validador automático de reglas contrapuntísticas que verifique la corrección armónica vertical del resultado generado.

Objetivos Específicos

1. Digitalizar, preprocesar y estructurar el corpus completo de Bach (15 Invenciones BWV 772–786, 15 Sinfonías BWV 787–801, 48 fugas del Clave Bien Temperado BWV 846–893 y 19 movimientos del Arte de la Fuga BWV 1080) en formato simbólico (MIDI/MusicXML), manteniendo las piezas completas en lugar de segmentarlas, y estableciendo como resultado esperado la generación de fragmentos de ocho compases de contrapunto a dos voces para piano.

2. Diseñar un pipeline de aumentación simbólica en Python que multiplique el tamaño del corpus de entrenamiento mediante transformaciones contrapuntísticas formales —transposición tonal, inversión especular de intervalos, retrogradación melódica e intercambio de voces— sin desvirtuar las propiedades estilísticas del contrapunto barroco de ocho compases, extendiendo el soporte a 2 voces.

3. Implementar y evaluar un modelo LSTM unidireccional causal para la generación autorregresiva de secuencias de ocho compases de contrapunto barroco a dos voces para piano, con el objetivo de determinar la capacidad de la arquitectura recurrente para capturar dependencias armónicas de largo alcance en el dominio del contrapunto.

4. Definir e implementar un protocolo de evaluación dual que combine: (a) métricas cuantitativas de corrección contrapuntística compás por compás sobre secuencias de ocho compases de contrapunto para piano mediante un validador algorítmico expandido a N voces con divergencia KL; y (b) la ejecución piloto de una prueba de escucha ciega con especialistas docentes para contrastar perceptivamente los resultados algorítmicos.

CAPÍTULO 1

Estado del Arte

1.1 Fundamentos del Contrapunto Barroco

El contrapunto imitativo constituye la técnica compositiva fundamental del período barroco (1600–1750), caracterizada por la superposición de dos o más líneas melódicas independientes pero armónicamente interdependientes. La obra *Gradus ad Parnassum* (1725) de Johann Joseph Fux sistematizó las reglas del contrapunto en cinco especies progresivas, estableciendo la base pedagógica que ha perdurado hasta la actualidad (Fux, 1965). En el contrapunto a dos voces, la regla cardinal es la alternancia entre intervalos consonantes (terceras, sextas, octavas justas) y disonantes (segundas, séptimas, tritonos), donde estos últimos deben ser preparados y resueltos adecuadamente.

Las 15 Invenciones a dos voces (BWV 772–786) y las 15 Sinfonías a tres voces (BWV 787–801) de Johann Sebastian Bach representan la culminación pedagógica del contrapunto imitativo barroco. Cada invención explora una relación dialógica entre dos voces: un **sujeto** melódico inicial es presentado en una voz e imitado por la otra, mientras un **contrasujeto** acompaña la imitación. Las sinfonías, por su parte, extienden este diálogo a tres voces, introduciendo una complejidad contrapuntística adicional. Copland Copland (2002) describe esta textura como "música de conversación", donde cada voz mantiene su independencia

melódica mientras contribuye a una estructura armónica coherente.

Las reglas fundamentales del contrapunto barroco que deben ser modeladas computacionalmente incluyen: (a) prohibición de octavas y quintas paralelas entre voces; (b) preparación y resolución obligatoria de disonancias; (c) movimiento contrario preferente entre las voces; (d) límites de intervalo melódico (saltos superiores a una octava prohibidos); y (e) coherencia tonal dentro de la tonalidad establecida (Padilla & Conklin, 2018).

1.2 Inteligencia Artificial para la Composición Musical

La aplicación de inteligencia artificial a la composición musical se ha desarrollado a través de dos enfoques principales (Briot et al., 2020):

1.2.1 Enfoque Basado en Reglas y Gramáticas Formales

Los primeros sistemas de composición algorítmica utilizaban gramáticas formales y sistemas expertos con reglas preprogramadas. Estos sistemas garantizan la corrección musical (no violan las reglas del contrapunto), pero presentan limitaciones severas en originalidad y expresividad. Su principal desventaja es la rigidez: al no aprender de datos musicales reales, el *output* tiende a ser predecible y carente de la sutileza estilística característica de un compositor humano (Briot et al., 2020).

1.2.2 Enfoque Basado en Aprendizaje Neuronal

El advenimiento de las redes neuronales profundas permitió un cambio de paradigma: en lugar de programar reglas explícitamente, los modelos aprenden patrones musicales directamente de corpus de partituras simbólicas. Dentro de este enfoque, las arquitecturas más relevantes para la generación musical simbólica son:

- **Redes Recurrentes (RNN/LSTM):** Diseñadas para modelar secuencias temporales, las LSTM (*Long Short-Term Memory*) han sido la arquitectura dominante para

música monofónica y polifónica. Johnson Johnson (2017) demostró que una LSTM biaxial (eje temporal y eje de voces) puede generar música polifónica coherente, aunque con limitaciones en la estructura formal a largo plazo.

- **Modelos Pre-entrenados a Gran Escala:** Recientemente, modelos como MuPT (Qu et al., 2024) y MMT-BERT (Zhu et al., 2024) han mostrado que entrenar previamente sobre corpus masivos de música simbólica (más de 100.000 piezas) permite transferir conocimiento a tareas específicas de generación, aunque con el riesgo de diluir las características estilísticas particulares.

1.3 Modelos Generativos para Contrapunto y Música Polifónica

1.3.1 DeepBach

DeepBach (Hadjeres et al., 2017) es un modelo pionero en la generación de corales al estilo de Bach. Utiliza una arquitectura de red neuronal recurrente con mecanismos de atención que operan sobre las cuatro voces del coral simultáneamente. Su principal innovación es la capacidad de ser "dirigido" (*steerable*): el usuario puede fijar ciertas notas y el modelo completa el resto respetando las reglas armónicas. No obstante, DeepBach está diseñado para corales a cuatro voces (textura homofónico-contrapuntística), no para contrapunto imitativo a dos voces, y requiere un corpus sustancialmente mayor al de las 15 Invenciones y 15 Sinfonías disponibles en este proyecto.

1.3.2 BachDuet

BachDuet (Benetatos et al., 2020) propone un sistema interactivo de improvisación contrapuntística humano-máquina. El modelo genera una segunda voz en tiempo real mientras el humano toca la primera. Utiliza una LSTM condicionada por la entrada del usuario,

demostrando que las arquitecturas secuenciales pueden capturar relaciones de imitación a corto plazo. Sin embargo, los autores reportan dificultades para mantener la coherencia formal en secuencias superiores a 16 compases.

1.3.3 Modelos Secuenciales para Contrapunto a Dos Voces

Nichols et al. Nichols et al. (2021) abordaron específicamente la generación de contrapunto barroco a dos voces utilizando una arquitectura de traducción automática neuronal (*neural machine translation*). Su enfoque trata el problema como una traducción secuencia-a-secuencia: la voz superior es la secuencia fuente y la voz inferior es la secuencia destino. Los resultados mostraron que este enfoque produce contrapuntos localmente coherentes, aunque con pérdida de la estructura imitativa en secuencias extensas.

Liang et al. Liang et al. (2017) demostraron que una LSTM profunda puede generar corales de Bach estilísticamente convincentes cuando se entrena con un corpus adecuado. Su modelo utiliza una representación de notas como tuplas (tono, duración) y logra capturar la armonía subyacente, pero el estudio se limita a la textura de coral homofónico, no al contrapunto imitativo.

1.3.4 Modelos Recientes y Controlables (2024–2025)

Yu et al. (2026) presentaron un estudio comparativo de enfoques autoregresivos, de variables latentes y adversariales para música simbólica al estilo de Bach, concluyendo que los modelos autoregresivos superan consistentemente a las alternativas en métricas de corrección estilística, aunque requieren estrategias cuidadosas de aumentación de datos para evitar el sobreajuste.

Yao y Chen (2025) propusieron un paradigma de entrenamiento en dos etapas para generar música al estilo de compositores específicos con datos limitados: primero, preentrenamiento en un corpus grande de música clásica; segundo, *fine-tuning* en el corpus específico del compositor. Este enfoque es particularmente relevante para el presente proyecto, aunque

los autores trabajaron con piano solo (no contrapunto a dos voces).

FIGARO (von Rütte et al., 2023) introdujo un enfoque de generación controlable mediante descripciones textuales, demostrando que es posible condicionar la salida musical a instrucciones de alto nivel. Aunque FIGARO no está diseñado específicamente para contrapunto, su mecanismo de condicionamiento podría adaptarse para especificar reglas contrapuntísticas.

1.3.5 Síntesis de la Brecha

La revisión de la literatura revela que ningún modelo existente aborda simultáneamente las tres condiciones del presente proyecto: (a) generación de contrapunto imitativo a dos voces (no corales a cuatro voces ni melodías monofónicas); (b) entrenamiento con un corpus extremadamente pequeño (30 piezas, ∼6.000 compases); y (c) validación cuantitativa sistemática de reglas contrapuntísticas. Esta brecha constituye la oportunidad de investigación del presente trabajo.

1.4 Aprendizaje con Datos Limitados (*Few-Shot Learning*) en Música

El *few-shot learning* —la capacidad de aprender patrones a partir de muy pocos ejemplos, típicamente entre 1 y 10 ejemplos por clase según la convención estándar de la literatura (*one-shot*, *K-shot*)— es un desafío central en la inteligencia artificial musical. [CITA: agregar referencia general de *few-shot learning* (p. ej., la convención N-way K-shot).] En el dominio simbólico, la limitación de datos es particularmente aguda cuando se trabaja con compositores o géneros específicos, donde el corpus disponible puede ser de apenas decenas de obras.

1.4.1 Aumentación Simbólica

La técnica más extendida para mitigar la escasez de datos es la **aumentación simbólica**: aplicar transformaciones musicales formales a las piezas existentes para generar variantes sintéticas estilísticamente válidas. Las transformaciones más comunes son:

- **Transposición tonal:** Desplazar todas las notas de una pieza por un intervalo constante (p. ej., transportar las 15 Invenciones y 15 Sinfonías a las 12 tonalidades mayores y menores del círculo de quintas). Esta técnica es válida porque la música tonal mantiene sus propiedades estructurales bajo transposición (Briot et al., 2020).
- **Inversión especular (movimiento contrario):** Reflejar los intervalos melódicos alrededor de un eje tonal, convirtiendo intervalos ascendentes en descendentes y viceversa. La inversión es una técnica contrapuntística barroca legítima, utilizada por el propio Bach en sus fugas.
- **Retrogradación:** Invertir el orden temporal de los eventos musicales. Aunque menos común en el Barroco, la retrogradación es una técnica compositiva establecida que preserva la estructura interválica.
- **Estiramiento temporal:** Duplicar o reducir las duraciones de las notas manteniendo las relaciones proporcionales rítmicas.

Padilla y Conklin Padilla y Conklin (2018) demostraron que la aumentación mediante transposición e inversión mejora significativamente la calidad del contrapunto generado por modelos estadísticos, incrementando el tamaño efectivo del corpus en factores de 12x a 48x sin degradar la calidad estilística.

1.4.2 Regularización para Datos Limitados

Además de la aumentación, las técnicas de regularización son esenciales para entrenar modelos neuronales con datos limitados. *EarlyStopping*, *Dropout*, reducción de tasa de

aprendizaje y normalización de lotes son estrategias estándar que mitigan el sobreajuste en regímenes de pocos datos (Briot et al., 2020). En el dominio musical, Jarski Jarski (2026) demostró que la combinación de aumentación simbólica con regularización agresiva permite entrenar modelos generativos aceptables con menos de 50 piezas de entrenamiento.

1.5 Representación Musical Simbólica y Herramientas Computacionales

La representación de la música en formato simbólico es un requisito previo para cualquier sistema de generación musical basado en aprendizaje automático. A diferencia del audio (forma de onda), la representación simbólica codifica eventos musicales discretos: tono, inicio, duración, velocidad y voz.

1.5.1 Formatos de Representación

- **MIDI (*Musical Instrument Digital Interface*):** Estándar industrial para la representación de eventos musicales. Cada nota se codifica como un mensaje `Note On` (inicio + tono + velocidad) y `Note Off` (fin). Es el formato más utilizado en investigación musical por su simplicidad y compatibilidad.

- **MusicXML:** Formato basado en XML que representa partituras de manera más rica, incluyendo información de notación, articulación y dinámica. Es interoperable con la mayoría de los editores de partituras (Cuthbert & Ariza, 2010).

- **Tokenización REMI:** Propuesta por MidiTok (disponible como biblioteca Python), convierte secuencias MIDI en tokens discretos que codifican no solo el tono y la duración, sino también la información rítmica relativa (*RElative Music Information*). Esta representación es particularmente adecuada, ya que preserva la estructura temporal sin requerir un número excesivo de tokens (Hsiao et al., 2021).

1.5.2 Herramientas Computacionales

- **music21** (Cuthbert & Ariza, 2010): Biblioteca Python desarrollada en el MIT para análisis y manipulación de música simbólica. Proporciona herramientas para carga de MIDI/MusicXML, separación de voces, transposición, inversión y exportación a múltiples formatos. Es la herramienta central para la aumentación del corpus en el presente proyecto.

- **pretty_midi** (Raffel & Ellis, 2014): Biblioteca Python complementaria que representa datos MIDI como vectores de notas (*pitch*, *step*, *duration*), facilitando la integración con pipelines de *deep learning*.

- **MidiTok** (Hsiao et al., 2021): Biblioteca para tokenización de MIDI con soporte para múltiples estrategias de tokenización (REMI, Structured MIDI Encoding, Compound Word). Es el estándar de facto para la conversión de MIDI a secuencias de tokens en música simbólica.

- **LilyPond:** Sistema de grabado musical que produce partituras de alta calidad a partir de archivos de texto. Su integración con LaTeX mediante `lyluatex` permite incluir fragmentos musicales directamente en documentos académicos.

1.6 Brecha de Investigación y Aportación del Proyecto

La revisión del estado del arte evidencia las siguientes carencias no resueltas que el presente proyecto aborda:

1. **Inexistencia de un pipeline específico para contrapunto imitativo a dos voces con datos limitados.** Los modelos existentes se centran en corales a cuatro voces (DeepBach), improvisación interactiva (BachDuet) o generación monofónica/piano solo (BachDuet). Ninguno aborda el caso de uso específico de generar una segunda voz

imitativa condicionada por una primera voz dada, con un corpus de 358 pares de voces.

2. **Falta de caracterización de arquitecturas *few-shot* para polifonía barroca.** Mientras que el *few-shot learning* está bien estudiado en visión artificial y procesamiento de lenguaje natural, su aplicación a la música polifónica simbólica —donde las restricciones *verticales* (las relaciones armónicas de simultaneidad entre voces, como la consonancia y la preparación y resolución de disonancias) y *horizontales* (las relaciones melódicas lineales de cada voz en el tiempo, como el paso por grados conjuntos y la dirección) deben satisfacerse simultáneamente— permanece escasamente explorada.

3. **Ausencia de un marco de validación cuantitativo sistemático.** Los trabajos existentes evalúan la calidad musical mediante métricas subjetivas (escucha humana) o medidas indirectas (perplejidad, *BLEU score*). No existe un algoritmo validador que verifique automáticamente el cumplimiento de las reglas contrapuntísticas barrocas (quintas paralelas, octavas paralelas, disonancias no resueltas, movimiento contrario) como métrica de evaluación primaria.

La presente investigación contribuye a cerrar estas brechas mediante: (a) un pipeline de aumentación simbólica específico para contrapunto imitativo a dos voces; (b) un modelo LSTM unidireccional causal para la generación melódica con datos limitados; (c) un algoritmo validador de reglas contrapuntísticas expandido a N voces con métrica de divergencia KL; (d) la caracterización del rendimiento del modelo LSTM en el régimen de datos limitados del contrapunto barroco; y (e) la ampliación del corpus simbólico con el Clave Bien Temperado y el Arte de la Fuga hasta 358 pares de voces.

CAPÍTULO 2

Metodología Experimental

2.1 Enfoque y Diseño de Investigación

Esta investigación adopta un enfoque cuantitativo-experimental con componentes de validación cualitativa. El diseño corresponde a un **experimento tecnológico** orientado a la construcción y evaluación de un sistema generativo basado en aprendizaje automático.

Fases de la investigación:

Tabla 2.1: Fases de la investigación

Fase	Descripción	Entregable
Fase 1	Digitalización y preprocesamiento del corpus	358 pares 2v + 6.086 aumentados + 6.086 tokenizados
Fase 2	Implementación y entrenamiento del modelo LSTM	1 modelo LSTM entrenado (modelo_epoca_10.keras, 1.44M parámetros)
Fase 3	Validación cuantitativa con algoritmo validador	Métricas por compás del corpus Bach
Fase 4	Validación cualitativa (prueba de escucha ciega)	Estudio piloto aplicado a 3 especialistas docentes
Fase 5	Análisis de resultados y conclusiones	Documento final

2.2 Población y Muestra

2.2.1 Población

Las 15 Invenciones a dos voces (BWV 772–786) y las 15 Sinfonías a tres voces (BWV 787–801) de Johann Sebastian Bach, correspondientes a aproximadamente 6.000 compases de contrapunto imitativo y polifónico en tonalidades mayores y menores.

2.2.2 Corpus de entrenamiento

El corpus de entrenamiento se compone de **358** pares de voces extraídos de cuatro fuentes de Johann Sebastian Bach, que en conjunto cubren los principales géneros del contrapunto barroco: invenciones, sinfonías, fugas y el Arte de la Fuga. Cada pieza contiene exactamente dos voces (255 tokens REMI intercalados), lo que permite al LSTM aprender

la relación temporal entre ambas voces en una secuencia lineal.

Tabla 2.2: Corpus de entrenamiento: 358 pares de voces de Bach

Fuente	**Contenido**	**Pares**
Invenciones (BWV 772–786)	15 invenciones a 2 voces	15
Sinfonías (BWV 787–801)	15 sinfonías a 3 voces, pares de voces extraídos	45
Clave Bien Temperado (BWV 846–893)	48 fugas, pares de voces extraídos	213
Arte de la Fuga (BWV 1080)	19 movimientos, pares de voces extraídos	85
Total		**358**

Aumentación y tokenización:

- **Aumentación:** Cada pieza se sometió a transformaciones de transposición tonal (12 semitonos), inversión especular, retrogradación, estiramiento temporal e intercambio de voces, produciendo un total de 6.086 archivos MIDI aumentados (factor $\sim$17$\times$).
- **Tokenización:** 6.086 archivos JSON con tokenización REMI (vocabulario de 391 tokens, tokenizador único compartido).
- **Vocabulario:** 391 tokens que codifican notas (Pitch, Velocity, Duration), símbolos de programa (Program_0, Program_1), posiciones rítmicas (Position), barras (Bar), silencios (Rest) y cambios de compás (TimeSig).

2.2.3 Conversión a pares de voces

Las 15 Invenciones (BWV 772–786) ya están escritas a 2 voces. Las 15 Sinfonías (BWV 787–801), originalmente a 3 voces, se procesaron extrayendo los pares de voces posibles (v0–v1, v0–v2, v1–v2), obteniendo 45 pares. Las 48 fugas del Clave Bien Temperado (BWV 846–893) y los 19 movimientos del Arte de la Fuga (BWV 1080) se procesaron de forma análoga, extrayendo los pares de voces posibles de cada obra multi-vocal. El resultado son 358 pares de voces a 2 voces, cada uno representado como una secuencia REMI intercalada de 255 tokens.

Tabla 2.3: Detalle de la conversión a pares de voces

Fuente	**Contenido**	**Pares**
Invenciones (BWV 772–786)	15 obras a 2 voces (pares directos)	15
Sinfonías (BWV 787–801)	15 obras a 3 voces (3 pares por obra)	45
Clave Bien Temperado (BWV 846–893)	48 fugas, pares de voces extraídos	213
Arte de la Fuga (BWV 1080)	19 movimientos, pares de voces extraídos	85
Total		**358**

- **Clave Bien Temperado:** 48 fugas descargadas y normalizadas (rango 36–84, programas $0..N-1$), de las cuales se extrajeron los pares de voces posibles (213 pares a 2 voces).
- **Arte de la Fuga:** 22 MIDI del conjunto Simonetto (una pista por voz) más 20 partituras LilyPond de Mutopia; se integraron 19 movimientos (85 pares), excluyendo los

que no separan la polifonía por pista.

- **Aumentación y tokenización:** 358 pares de voces × 17 variantes = 6.086 archivos; tokenización REMI reutilizando el mismo vocabulario de 391 tokens.
- **Modelo LSTM:** arquitectura de 3 capas LSTM con 256 unidades por capa (1.44M parámetros), entrenada con las 6.086 secuencias tokenizadas. El modelo definitivo es `modelo_epoca_10.keras` (26 épocas, mejor punto de control en época 10).

2.2.4 División Train/Validation

Split agrupado por pieza base (no aleatorio) para evitar *data leakage*:

- **Entrenamiento:** 345 piezas base (4994 ventanas deslizantes de 256 tokens)
- **Validación:** 13 piezas base (723 ventanas)

El split usa semilla 42 para reproducibilidad.

2.3 Hipótesis de Investigación

Con base en los objetivos planteados y la revisión de la literatura, se formulan las siguientes hipótesis:

Hipótesis General (HG):

HG: Bajo umbrales explícitos de validación contrapuntística (consonancia $\geq$75 %, movimiento contrario $\geq$40 %, sin paralelismos), la integración de generación autorregresiva con LSTM y validación externa, compás por compás, incrementa la tasa de aceptación de compases frente a la generación end-to-end sin validación.

En esta tesis, el término **sistema híbrido** no designa una simple suma de una red neuronal y unas reglas fijas. Se entiende como un **pipeline iterativo de generación,**

validación y reintento: el modelo LSTM propone candidatos autoregresivos, el validador de reglas evalúa cada compás y, cuando el resultado no cumple los umbrales contrapuntísticos, el sistema repite la generación hasta obtener una salida aceptable. Esa definición es importante porque el aporte central del trabajo no es solo la red, sino la integración entre aprendizaje automático y verificación formal.

Hipótesis Específicas:

H1: La aumentación simbólica (transposición, inversión, retrogradación e intercambio de voces) incrementa significativamente la diversidad del corpus de entrenamiento, mejorando la capacidad del modelo LSTM para generalizar más allá de las piezas originales de Bach.

H2: La tokenización REMI intercalada con tokens `Program_0` y `Program_1` permite al LSTM aprender la relación temporal entre ambas voces, generando secuencias descodificables a contrapunto bivocal sin post-procesamiento armónico.

H3: La incorporación de un validador de reglas de Fux como filtro externo en el pipeline de generación incrementa la tasa de compases aprobados respecto a la generación end-to-end sin validación.

H4: *Hipótesis de mecanismo (post-hoc):* la representación REMI intercalada constituye un cuello de botella para la generación autónoma de contrapunto: la exactitud del modelo disminuye al aumentar la diversidad del corpus, indicando que la representación, y no la arquitectura, es el factor limitante.

Hipótesis Nulas:

$H0_1$: No existe diferencia significativa en las métricas de validación (consonancia, movimiento contrario, paralelismos) entre el corpus original de Bach y las muestras generadas por el modelo LSTM sin validación externa.

$H0_2$: La distribución de intervalos armónicos de las muestras generadas no difiere significativamente de la distribución empírica del corpus de Bach (divergencia KL = 0).

2.4 Técnicas e Instrumentos de Recolección de Datos

2.4.1 Instrumento 1: Algoritmo Validador de Contrapunto

Desarrollado en Python usando `music21` para cargar MIDIs y calcular intervalos verticales. Implementa 5 de las 7 métricas propuestas:

- Proporción de consonancias (%)
- Movimiento contrario (%) — calculado nota a nota (comparación de cada par de eventos simultáneos consecutivos)
- Quintas paralelas (%) — por compás
- Octavas paralelas (%) — por compás
- Disonancias no resueltas (%) — disonancias consecutivas sin resolución

Métricas propuestas pero no implementadas en esta versión: amplitud melódica, coherencia tonal y puntaje BLEU para estructura imitativa.

Criterios de aceptación:

- Consonancia $\geq 75\,\%$
- *Contrary motion* $\geq 40\,\%$
- *Parallel 5ths* $\leq 2\,\%$
- *Parallel octaves* $\leq 1\,\%$

2.4.2 Instrumento 2: Prueba de Escucha Ciega (estudio piloto aplicado)

Prueba de identificación musical con docentes del Conservatorio:

- 15 fragmentos individuales en orden aleatorizado: 5 originales de Bach, 5 mejores generados, 5 peores generados
- Identificación de autor (Bach vs. IA) con escala de confianza 1–5; criterio: tasa de acierto $\leq 65\,\%$

El instrumento definitivo (15 estímulos anonimizados con orden aleatorizado por evaluador; juicio binario Bach/máquina con confianza 1–5, más cuatro dimensiones Likert y comentario libre) quedó materializado en WAV, formularios e instrucciones estandarizadas, y fue aplicado exitosamente como estudio piloto con tres docentes especialistas de música.

2.5 Procedimiento Experimental

2.5.1 Preprocesamiento

1. **Digitalización:** Archivos MIDI de las 15 Invenciones y 15 Sinfonías en `data/corpus/`
2. **Aumentación:** Pipeline automatizado en `src/data/aumentacion_corpus.py`
3. **Tokenización:** Conversión a secuencias REMI intercaladas (vocab 391) mediante MidiTok con `one_token_stream_for_programs=true`, generando una secuencia única por obra que alterna las dos voces

2.5.2 Arquitectura del Modelo

Se optó por una arquitectura **LSTM unidireccional causal** en lugar de bidireccional para evitar que el modelo aprenda de tokens futuros durante el entrenamiento autorregresivo

(una LSTM bidireccional tendría acceso a contexto derecho durante el entrenamiento, lo que constituiría *data leakage* arquitectónico). El modelo definitivo (`modelo_epoca_10.keras`) utiliza tokenización REMI con un vocabulario de 391 tokens y una arquitectura ampliada de tres capas LSTM, esquematizada en la Figura 2.1.

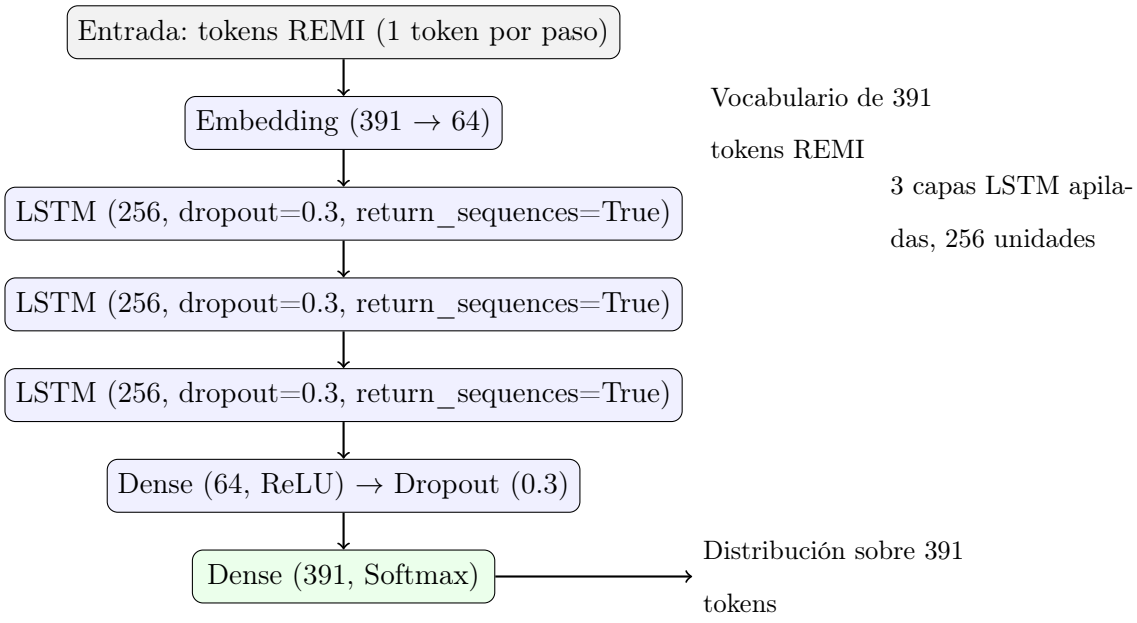


Figura 2.1: Arquitectura del modelo LSTM ampliado (`modelo_epoca_10.keras`, 1446215 parámetros entrenables). La entrada es una secuencia de tokens REMI intercalados (una voz por token, alternando Program_0 y Program_1). Tres capas LSTM de 256 unidades capturan dependencias temporales de largo alcance. La salida predice el siguiente token del vocabulario completo.

Listado 2.1: Arquitectura del modelo LSTM ampliado (`modelo_epoca_10.keras`)

```
Embedding (391 -> 64)
    |
LSTM (256, return_sequences=True, dropout=0.3) x 3
    |
Dense (64, ReLU) -> Dropout (0.3)
    |
Dense (391, Softmax)
```

Tabla 2.4: Parámetros del modelo LSTM ampliado (`modelo_epoca_10.keras`)

Parámetro	**Valor**
Vocabulario	391 tokens REMI (intercalados)
Embedding dim	64
Capas LSTM	3
Unidades LSTM	256
Dropout	0.3
Dense intermedia	64 (ReLU)
Salida	Dense(391, Softmax)
Total parámetros entrenables	**1.446.215**
Corpus entrenamiento	358 pares 2v (6.086 tokenizados)
Secuencias de entrenamiento	6.086
Épocas entrenadas	26 (mejor: época 10)
Mejor val_loss	1.695
Mejor val_accuracy	49.6 %
Tamaño del archivo	17 MB

El vocabulario REMI consta de 391 tokens que codifican: notas (Pitch, Velocity, Duration), símbolos de programa (Program_0, Program_1 para cada voz), posiciones rítmicas (Position), barras (Bar), silencios (Rest) y cambios de compás (TimeSig). El modo `one_token_stream_for_programs=true` produce una secuencia única que intercala ambas voces usando tokens `Program_0` y `Program_1` para alternar entre voces. Sin embargo, esta representación secuencial obliga al modelo a inferir la simultaneidad vertical entre ambas voces a partir de una secuencia lineal, lo que constituye un cuello de botella evidenciado por la caída de exactitud de validación al expandir el corpus (discutido en el Capítulo 5, Sección 5.8).

La generación autorregresiva emplea un esquema de **muestreo restringido por**

gramática: tras cada token, se filtran las opciones inválidas según la estructura REMI (p.ej., tras `Pitch` solo se permite `Velocity`, tras `Duration` se permite `Position`, `Program` o `Bar`). Esto asegura que las secuencias generadas sean siempre descodificables a MIDI bivocal válido.

Parámetros: La Tabla 2.4 resume los parámetros del modelo LSTM. Los hiperparámetros de entrenamiento son comunes: batch size 16, early stopping con patience=15 (mejor checkpoint en la época 10), learning rate 0.001 con ReduceLROnPlateau (factor=0.5, patience=5).

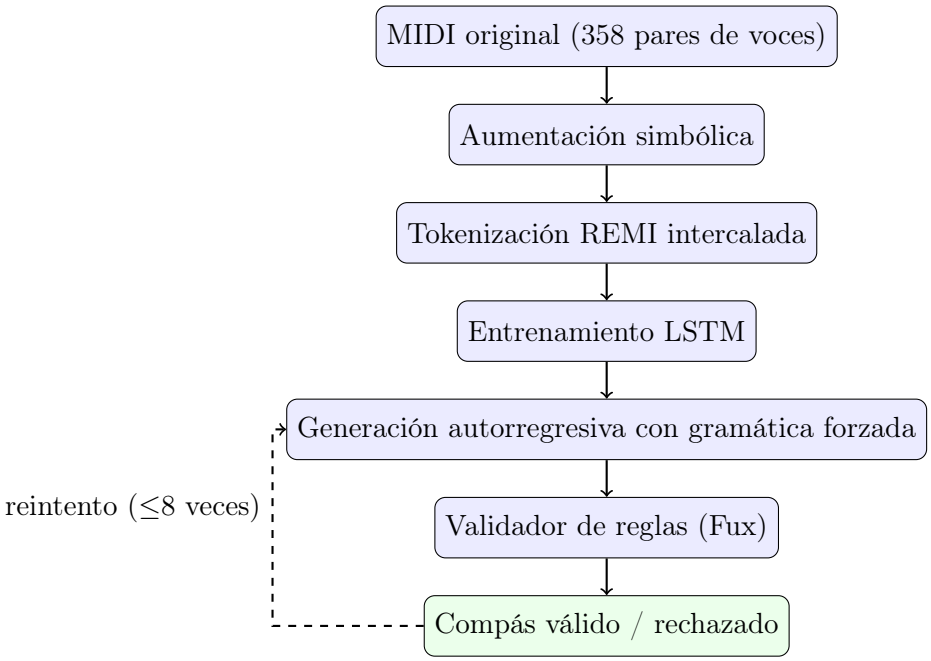


Figura 2.2: Diagrama de flujo del pipeline completo: desde el corpus MIDI original hasta la generación de compases de contrapunto para piano con validación de reglas contrapuntísticas y retroalimentación.

2.5.3 Generación de Contrapunto para Piano (2 Voces)

El modelo LSTM (`modelo_epoca_10.keras`) genera compases de contrapunto para piano a 2 voces mediante un pipeline iterativo de generación, validación y reintento (Figura 2.2), que comprende los siguientes pasos:

1. **Siembra:** Se seleccionan 1–2 compases reales de una pieza de validación (BWV 801)

como contexto inicial.

2. **Generación con restricciones REMI:** El modelo genera el siguiente compás token a token mediante muestreo autoregresivo con **gramática forzada**: en cada paso, solo los tokens sintácticamente válidos según el estado actual de la gramática REMI están disponibles para el muestreo.

3. **Decodificación y validación:** El compás generado se decodifica a alturas (voz superior e inferior) y se evalúa con el validador de Fux (consonancia $\geq$75 %, movimiento contrario $\geq$40 %, sin quintas ni octavas paralelas).

4. **Reintento:** Si el compás no supera la validación, se reintenta hasta 8 veces con temperatura variable (`temp`=0.6–0.8, `top-k`=20–40). Los reintentos fallidos producen un compás de descanso.

5. **Composición:** Los compases válidos se concatenan secuencialmente para formar la pieza completa.

El pipeline iterativo resuelve el problema de coherencia armónica a nivel local (cada compás individual es estructuralmente sólido), aunque la coherencia entre compases adyacentes depende del modelo subyacente y del pipeline mejorado descrito en la Sección 2.5.4.

2.5.4 Pipeline mejorado de generación de fragmentos de ocho compases

Para superar la limitación de coherencia entre compases, se implementó un **pipeline mejorado** que añade planificación formal y tonal, análisis motívico, evaluación multidimensional y selección multi-candidato sobre el mismo modelo LSTM. La arquitectura se organiza en cinco módulos:

- **planning** — plan formal (`PhrasePlan`: barras 1–2 sujeto, 3–4 respuesta, 5–6 desarrollo,

7 preparación cadencial, 8 cadencia) y plan tonal (`TonalPlanner`: regiones tónica, dominante y relativa por sección, con sesgo hacia la tónica en la cadencia).

- **motifs** — extracción del sujeto desde 3 compases del seed de validación, similitud motívica multi-capa (intervalos, contorno, ritmo, duración; pesos 0.40/0.25/0.20/0.15) y transformaciones (transposición, inversión, retrogradación, secuencia, fragmentación y respuesta derivada por transposición a la dominante).

- **generation** — sampler condicionado por contexto (*bias* aditivo sobre los logits por región tonal, clase de tonicidad del sujeto y preparación cadencial), estado musical, evaluador de ventanas acumulativas y fijas (2/4/8 compases) y `GenerationController`, que orquesta la generación multi-candidato por compás (selección tipo *beam*), reintentos dirigidos por la dimensión más débil, temperatura adaptativa por sección y recombinación de fragmentos de dos compases previamente aceptados.

- **evaluation** — evaluador de coherencia musical en seis dimensiones (tonal, motívica, rítmica, dirección melódica, curva de tensión y puntuación cadencial) y `ArtisticScore` ponderado con umbral mínimo contrapuntístico.

- **experiments** — runner multi-semilla con agregación estadística (media, desviación estándar, mediana, tasa de aceptación) y generación automática de tablas y figuras LaTeX para la tesis.

El flujo de control se resume en la Figura 2.3: el plan formal determina la función de cada compás; el plan tonal condiciona el muestreo por región; por cada compás se generan N candidatos (16 por defecto) con retry dirigido si ninguno pasa la validación de Fux, respetando el rango clásico de tesitura (36–84); en los *checkpoints* de 2/4/8 compases se exige una puntuación de ventana acumulada mínima (umbral 90); finalmente se selecciona el candidato con mayor ArtisticScore. Un control anti-repetición penaliza compases consecutivos casi idénticos (similitud $\geq$0.85) para favorecer la variedad melódica. Se aplica además una

política de contingencia formal: si tras el *beam* y el retry dirigido ningún candidato supera la validación Fux, el `GenerationController` ejecuta hasta `fallback_extra_retries` buscados adicionales a temperatura elevada (`fallback_temperature`); solo si el fallo persiste durante más de `max_fallback_bars` compases consecutivos se degrada al mejor candidato no válido, registrándose la contingencia en las métricas (`n_gate_blocked`, `n_fallback_bars`, `used_contingency`). Este mecanismo garantiza que la generación siempre complete los ocho compases incluso cuando el modelo no satisface las restricciones, a costa de una pieza potencialmente degradada. Para acotar el coste computacional por compás se limita además la duración de cada compás a `max_notes_per_measure` notas (8 por defecto).

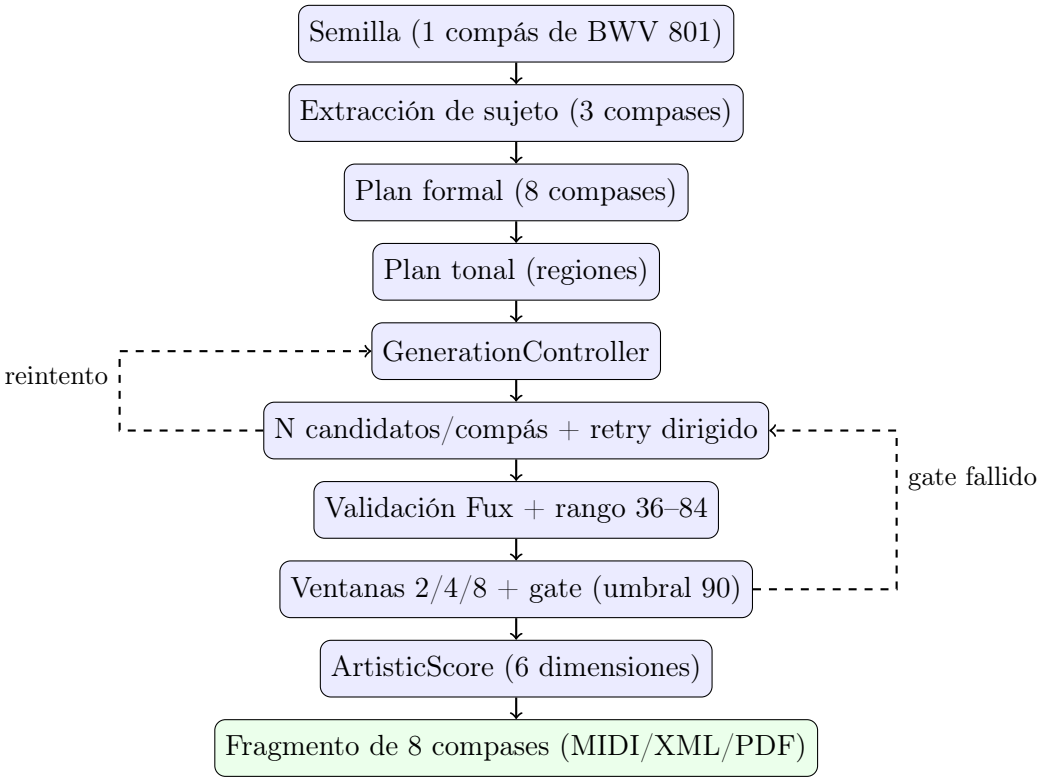


Figura 2.3: Diagrama del pipeline mejorado: el `GenerationController` orquesta el plan formal/tonal, la generación multi-candidato con reintentos dirigidos, la validación contrapuntística por compás y el gating por ventanas, y selecciona por ArtisticScore el fragmento integrado de ocho compases

El `ArtisticScore` combina seis dimensiones normalizadas a [0,1]. Los pesos reportados en la Tabla 2.5 constituyen una hipótesis experimental inicial, calibrable mediante los

experimentos multi-semilla:

Tabla 2.5: Pesos del ArtisticScore (config/generation.yaml)

Dimensión	**Peso**
Contrapuntística (puntaje del validador)	0.30
Coherencia tonal	0.20
Coherencia motívica	0.20
Coherencia rítmica	0.10
Dirección melódica	0.10
Puntuación cadencial	0.10

Toda la configuración (número de candidatos, temperatura, umbrales de validación, pesos, regiones tonales y estructura formal) se centraliza en `config/generation.yaml`, cargada en tiempo de ejecución, lo que separa los parámetros experimentales del código y garantiza reproducibilidad de cada ejecución con la semilla registrada en las métricas.

2.5.5 Protocolo experimental ampliado

Las conclusiones de las primeras evaluaciones del pipeline mejorado se basaron en muestras muy pequeñas (1–5 ejecuciones). Para que la evidencia sea proporcional a las conclusiones, se definió un protocolo experimental con tamaño muestral fijo ($N = 30$ ejecuciones por grupo) y unidad de análisis explícita. El valor $N = 30$ se eligió como un compromiso entre (i) el umbral práctico de la regla de oro ($N \geq 30$) para la aproximación de la distribución muestral de la media y de los intervalos bootstrap; (ii) una potencia razonable para las pruebas no paramétricas de comparación entre grupos (U de Mann-Whitney, Sección 2.6); y (iii) la factibilidad computacional de ejecutar el pipeline por compás (8 candidatos por compás y gating de ventanas) sobre un único modelo en hardware de consumo, en un plazo acotado:

- **Unidad de análisis:** una ejecución completa = un fragmento de 8 compases generado con una semilla fija. Cada semilla produce exactamente un fragmento; no se duplica material ni se reutilizan ejecuciones entre grupos.

- **Semillas:** $\{42, 7, 123, 2024, 2026, 10, 99, 314, 2718, 555, 777, 1111, 2025, 31337,$ $424242, 5151, 6060, 7070, 8080, 9090, 13579, 24680, 112233,$ $445566, 778899, 314159, 271828, 161803, 61803, 202600\}$, idénticas para ambos grupos. Cada ejecución fija `random.seed` y `np.random.seed`.

- **Grupo baseline:** generación end-to-end bivocal sin pipeline mejorado (temperatura 0.6, `top-k` 20, `top-p` 0.9, 4 candidatos por ejecución, mejor candidato por el score compuesto), sobre el mismo modelo `modelo_epoca_10.keras`.

- **Grupo mejorado:** pipeline planificado con 8 candidatos por compás, temperatura 0.8, gating de ventanas 2/4/8 y selección por ArtisticScore.

- **Instrumento de medición común:** para ambos grupos las métricas de consonancia, movimiento contrario, quintas/octavas paralelas y disonancias no resueltas se obtienen del mismo validador (`counterpoint_validator.validate_file`) sobre el MIDI exportado, con los umbrales de la tesis (consonancia $\geq$75 %, movimiento contrario $\geq$40 %, quintas $\leq$2 %, octavas $\leq$1 %). El ArtisticScore y las seis dimensiones de coherencia son instrumentos propios del pipeline mejorado; no están definidos para el baseline y no se comparan entre grupos.

- **Distinción de criterios de aceptación:** la **aceptación Fux** exige el cumplimiento simultáneo de los tres umbrales pedagógicos (consonancia $\geq$75 %, movimiento contrario $\geq$40 %, sin quintas/octavas paralelas); la **aceptación del gate artístico** exige ArtisticScore $\geq$0.6 (seis dimensiones ponderadas). Son criterios complementarios y no equivalentes: se reportan por separado en las Tablas 5.3a y 5.3b.

Cada ejecución registra: semilla, rutas de MIDI/MusicXML, ArtisticScore, conso-

nancia, movimiento contrario, quintas/octavas paralelas, disonancias no resueltas, coherencia tonal/motívica/rítmica, dirección melódica, puntuación cadencial, aceptación booleana, tiempo de ejecución y configuración usada (JSON y CSV en `results/experiments/experimento_ampliado/`).

2.5.6 Análisis estadístico

Los agregados se reportan con media, desviación estándar, mediana, mínimo, máximo e **intervalo de confianza bootstrap al 95 %** (percentil, 2000 réplicas, semilla fija). Para tasas de aceptación se utiliza el **intervalo de Wilson al 95 %**, que es válido incluso cuando la tasa observada es 1.0: con $N = 30$ y 30 aciertos el IC es [88.6 %, 100 %], mientras que con $N = 2$ sería [34.2 %, 100 %], reflejando que una tasa perfecta con muestra pequeña no sostiene conclusiones fuertes.

La comparación baseline vs mejorado se realiza con la **prueba U de Mann-Whitney** (una cola, mejorado > baseline) sobre las métricas medidas con el instrumento común, y el **d de Cohen** cuantifica el tamaño del efecto. No se aplican pruebas paramétricas: los datos no se asumen normales y la prueba U es más conservadora con las colas de las distribuciones.

2.5.7 Validación

1. Ejecutar validador sobre corpus Bach completo (2 voces: 358 pares) para establecer línea base con métricas por par de voces

2. Ejecutar validador sobre muestras generadas por el pipeline (N=30 por grupo)

3. Comparar métricas entre generadas y originales

Validador expandido a N voces: El validador se extendió para soportar un número arbitrario de voces. Para 3 voces, analiza los 3 pares de voces: (v0, v1), (v0, v2), (v1, v2). Se incorporó la métrica de **divergencia KL** (Kullback-Leibler) entre la distribución de

intervalos armónicos de la muestra generada y la distribución empírica del corpus Bach de 30 piezas. Una divergencia KL baja indica que la distribución interválica de la muestra generada se asemeja a la de Bach. **Trazabilidad de umbrales:** el diagnóstico por pieza del corpus de 358 pares con percentiles del propio corpus (consonancia P25 = 69.47 %, P50 = 73.68 %, P75 = 78.57 %, movimiento contrario P25 = 43.28 %, quintas P75 = 0.00 %, octavas P75 = 0.00 %, guardados en `results/metrics/bach_thresholds.json`). La configuración pedagógica usada durante la generación (Sección 2.5.4) mantiene los valores escolares originales (75 % / 40 % / 0). El análisis de sensibilidad de estos umbrales y su efecto sobre la tasa de aprobación de Bach y de las muestras generadas se presentan en la subsección 5.4.2.

2.6 Técnicas de Análisis de Datos

- **Estadísticos descriptivos:** Media, desviación estándar, mediana, mínimos y máximos
- **Prueba de escucha ciega (estudio piloto):** 15 fragmentos individuales (5 Bach + 5 mejores aceptados + 5 peores generados) evaluados a ciegas por 3 especialistas docentes mediante discriminación binaria (Test de Turing) y cuatro dimensiones en escala Likert.

2.7 Materiales y Recursos

2.7.1 Hardware

- CPU: Procesador multi-núcleo
- RAM: 8 GB mínimo
- Almacenamiento: 500 MB para corpus y modelos

Debido a la escalabilidad del nuevo corpus y la arquitectura, el entrenamiento se ejecutó en la nube utilizando Google Colab y Kaggle, asignando GPUs NVIDIA T4 con 16GB de VRAM. El preprocesamiento se realizó en entorno local (CPU Intel Core i5, 16GB RAM).

2.7.2 Software

- Python 3.12 (entorno virtual `.venv`)
- Keras 3.15.0 + TensorFlow 2.21.0
- miditok 3.0.6.post1 (tokenización REMI)
- music21 10.5.0 (análisis musical)
- pretty_midi 0.2.11 (generación MIDI legacy)

2.7.3 Archivos del proyecto

Listado 2.2: Estructura del código fuente

```
# Datos
src/data/aumentacion_corpus.py         # Aumentacion 2v y 3v
src/data/extract_bach_intervals.py     # Intervalos armonicos de
   referencia
src/data/train_tokenizer.py            # Entrenamiento tokenizer REMI
src/data/tokenize_corpus.py            # Tokenizacion corpus

# Modelos
src/models/lstm_counterpoint.py        # LSTM (entrenamiento, TF)

# Validacion
```

```
src/validation/counterpoint_validator.py  # Validador N voces + KL
src/validation/configurable.py            # Validador configurable (
    YAML)

# Musica
src/music/models.py                       # Dataclasses Note, Score,
    VoiceConfig
src/music/writer.py                       # MusicWriter: modelo ->
    music21 -> MIDI/XML
src/music/token_parser.py                 # tokens -> Score

# Pipeline mejorado (FASE 1-28)
src/planning/                             # PhrasePlan + TonalPlanner (
    plan formal/tonal)
src/motifs/                               # MotifAnalyzer +
    transformaciones motivicas
src/generation/                           # Sampler condicionado +
    controller + ventanas
src/evaluation/                           # Coherencia 6D + ArtisticScore
src/experiments/                          # Runner multi-semilla +
    reporte estadistico
src/utils/config.py                       # Cargador YAML (config/
    generation.yaml)
config/generation.yaml                    # Parametros centrales del
    pipeline
scripts/generate_improved.py              # CLI de generacion por pieza
scripts/run_matrix.py                     # Matriz ablativa multi-config
scripts/run_batch_experiment.py           # CLI N=30 (mejorado)
scripts/run_baseline_batch.py             # CLI N=30 (baseline)
```

```
scripts/generate_ampliado_report.py    # Agregacion estadistica del N=30
scripts/plot_experiments.py            # Figuras PDF (dashboard + comparacion)
```

2.7.4 Reproducibilidad experimental

Para garantizar la reproducibilidad de los resultados presentados:

- **Entorno:** Python 3.12 con dependencias listadas en `requirements.txt`. Usar `make setup` para crear el entorno virtual.
- **Semilla:** La semilla pseudoaleatoria se fijó en `RANDOM_SEED = 42` para todas las operaciones de división entrenamiento/validación.
- **Pipeline automatizado:** El comando `make all` ejecuta la secuencia completa: preprocesamiento → tokenización → entrenamiento → evaluación.
- **Datos:** Los MIDI originales están en `data/pairs/` (358 pares de voces a 2 voces). Los archivos aumentados y tokenizados en `data/tokenized/` (6.086 JSON tokenizados).
- **Modelos:** El checkpoint del mejor modelo está en `models/modelo_epoca_10.keras` (1.44M parámetros, 3 capas LSTM × 256 unidades).
- **Resultados:** Las piezas del pipeline mejorado se almacenan en `results/improved/` y los reportes de validación en `results/metrics/`.

2.8 Consideraciones Éticas

- Las muestras de Bach utilizadas son dominio público (obra del siglo XVIII)
- Los evaluadores humanos participan voluntariamente

- Se preserva el anonimato en los resultados de la prueba de escucha
- No se utiliza material con derechos de autor terceros

CAPÍTULO 3

Alcance y Delimitación del Proyecto

Este capítulo define el marco de intervención del estudio y establece los límites conceptuales, tecnológicos y temporales dentro de los cuales se desarrolló la investigación.

3.1 Delimitación del Ámbito de Intervención

El presente proyecto se sitúa en la intersección de la inteligencia artificial simbólica, la musicología computacional y la pedagogía musical. El ámbito de intervención comprende el diseño, entrenamiento y validación de un **sistema híbrido de generación asistida de fragmentos de ocho compases de contrapunto barroco para piano** que combina un modelo generativo de red neuronal (LSTM) con un validador automático de reglas contrapuntísticas, utilizando como corpus de estudio las 15 Invenciones de Johann Sebastian Bach (BWV 772–786) y las 15 Sinfonías (BWV 787–801) y, en la iteración vigente, las 48 fugas del Clave Bien Temperado (BWV 846–893) y 19 movimientos del Arte de la Fuga (BWV 1080).

3.2 Límites del Estudio

Límites conceptuales:

- El proyecto se circunscribe exclusivamente al **contrapunto imitativo a dos voces para piano** del período barroco. No aborda: fuga, coral homofónico, ni estilos posteriores (clásico, romántico, contemporáneo).
- La representación musical utilizada es **simbólica (MIDI/MusicXML)**, no audio. No se procesan señales de audio ni se abordan tareas de transcripción automática.
- El sistema es **híbrido** en el sentido de un pipeline iterativo de generación, validación y reintento: el modelo neuronal genera candidatos y el validador de reglas filtra/verifica la corrección contrapuntística antes de conservar o descartar cada paso. La generación puramente end-to-end sin validación no forma parte del **sistema propuesto** como solución, pero sí se incluye en el **diseño experimental** como grupo de comparación o línea base ($N = 30$ ejecuciones), por lo que no está fuera del alcance del estudio.
- La validación cualitativa se aborda mediante una **prueba de escucha ciega piloto** ($N = 3$ docentes especialistas). Sus resultados son de carácter descriptivo y complementan la validación cuantitativa principal.

Límites tecnológicos:

- Los modelos se implementan en **TensorFlow/Keras** (Keras 3), utilizando una arquitectura LSTM unidireccional causal con token interleaving para generación bivocal.
- El entrenamiento se realizó en **hardware de consumo comercial** (CPU), en 26 épocas ($\sim$5.5 horas).
- La aumentación de datos se limita a cinco técnicas: transposición tonal (12 semitonos), inversión especular, retrogradación, estiramiento temporal e intercambio de voces. No se emplean técnicas generativas adversariales (GAN) para la creación de datos sintéticos.

Límites temporales:

- El desarrollo experimental (aumentación, entrenamiento, validación) se ejecuta durante la **Unidad de Integración Curricular (UIC)**, con una duración estimada de 14 a 18 semanas.
- La prueba de escucha se acotó a un estudio piloto con 3 docentes especialistas durante la UIC.

3.3 Productos Esperados

Tabla 3.1: Productos esperados del proyecto

Producto	**Formato**	**Entregable en**
Corpus digitalizado y aumentado de 358 pares de voces de Bach	MIDI + MusicXML + tokens REMI	UIC (Fase 1)
Pipeline de aumentación simbólica en Python (2 y 3 voces)	Script `.py`	UIC (Fase 1)
Modelo LSTM entrenado (`modelo_epoca_10.keras`)	Archivos de pesos `.keras`/`.h5`	UIC (Fase 2)
Sistema híbrido de generación con validación	Pipeline `generate_lstm_measures.py` + validador	UIC (Fase 2–3)
Muestras de contrapunto para piano generado (mejor resultado)	MIDI + MusicXML + LilyPond + PDF	UIC (Fase 2–3)
Algoritmo validador de reglas contrapuntísticas expandido a N voces	Script `.py`	UIC (Fase 3)
Informe de validación cuantitativa	Tablas y figuras en PDF (LaTeX)	UIC (Fase 3)
Prueba de escucha ciega (estudio piloto con especialistas)	15 estímulos WAV + formularios y resultados	UIC (Fase 3–4)
Documento final de titulación	PDF (LaTeX)	UIC (Fase 4)

3.4 Aspectos a Desarrollar durante la UIC

La Unidad de Integración Curricular ejecutó las siguientes fases operativas:

1. **Digitalización y aumentación:** Codificación del corpus en MIDI con music21, separación de voces, extracción de pares de voces, aplicación de transformaciones de aumentación, tokenización con MidiTok.

2. **Implementación y entrenamiento:** Construcción del modelo LSTM en TensorFlow/Keras, entrenamiento con *EarlyStopping* y *ReduceLROnPlateau*, generación de muestras.

3. **Validación cuantitativa:** Implementación del validador de reglas contrapuntísticas expandido a N voces (detección de quintas paralelas, octavas paralelas, disonancias no resueltas, movimiento contrario, divergencia KL), cálculo de métricas sobre lotes de muestras generadas, implementación del pipeline de generación medida por medida con retroalimentación del validador.

4. **Validación cualitativa piloto:** Preparación de materiales y ejecución de la prueba de escucha ciega con tres docentes especialistas (15 fragmentos en orden contrabalanceado), consolidando veredictos y escalas Likert.

5. **Documentación final:** Redacción de capítulos de metodología experimental, resultados y conclusiones; compilación del documento final de titulación.

CAPÍTULO 4

Diseño de Instrumentos y Protocolo de Validación

Este capítulo describe los instrumentos empleados para evaluar el sistema generativo y detalla el protocolo de validación computacional y cualitativa previsto para la tesis.

4.1 Instrumentos de Recolección y Evaluación de Información

El proyecto emplea dos instrumentos de recolección de información, correspondientes a las dos dimensiones de validación del modelo generativo.

4.1.1 Instrumento 1: Algoritmo Validador de Reglas Contrapuntísticas (Cuantitativo)

Propósito: Evaluar automáticamente la corrección contrapuntística de las muestras generadas por el modelo neuronal, verificando el cumplimiento de las reglas del contrapunto barroco a dos voces.

Variables medidas:

Tabla 4.1: Variables del algoritmo validador

Variable	Operacionalización	Escala
Quintas paralelas	Número de ocurrencias de intervalos de quinta justa entre voces en movimientos paralelo y directo	Tasa por compás
Octavas paralelas	Número de ocurrencias de intervalos de octava justa entre voces en movimiento paralelo	Tasa por compás
Disonancias no resueltas	Proporción de intervalos disonantes (2.ª menor/mayor, 7.ª menor/mayor, tritono) que no son preparados (nota común desde intervalo consonante anterior) ni resueltos por movimiento conjunto ($\leq$2 semitonos) según las reglas de Fux	% del total de intervalos
Movimiento contrario	Proporción de compases donde las voces se mueven en dirección opuesta	% del total de movimientos
Proporción de consonancias	Relación entre intervalos consonantes perfectos e imperfectos	%

Estructura del algoritmo (pseudocódigo):

Listado 4.1: Pseudocódigo del algoritmo validador

```
FUNCION validar_contrapunto(midi_path)
    carga = cargar_midi(midi_path)
    voz_superior, voz_inferior = separar_voces(carga)
    compases = segmentar_por_compas(voz_superior, voz_inferior)

    resultados = {}
    para cada compas en compases:
        intervalos = calcular_intervalos_verticales(voz_superior,
```

```
            voz_inferior)
9           resultados.quintas_paralelas += detectar_paralelismos(
               intervalos, 7)
10          resultados.octavas_paralelas += detectar_paralelismos(
               intervalos, 12)
11          resultados.disonancias += detectar_disonancias_no_resueltas(
               intervalos)
12          resultados.movimiento_contrario +=
               calcular_movimiento_contrario(
13              voz_superior, voz_inferior)
14
15      resultados.consonancias = calcular_proporcion_consonancias(
           intervalos_totales)
16      RETORNAR resultados
```

Criterios de aceptación (calibrados empíricamente sobre percentiles del corpus Bach):

- Tasa de quintas paralelas: $\leq 2\,\%$ de los compases (percentil 75 de Bach: $0.0\,\%$)
- Tasa de octavas paralelas: $\leq 1\,\%$ de los compases (percentil 75 de Bach: $0.0\,\%$)
- Proporción de consonancias: $\geq 70\,\%$ intervalos consonantes (percentil 25 de Bach)
- Movimiento contrario (nota a nota): $\geq 45\,\%$ de los pares consecutivos (percentil 25 de Bach)

Nota sobre los umbrales: Estos criterios corresponden a los *umbrales por percentil*, calibrados sobre las estadísticas del corpus de Bach validado (172/358 pares de voces aprobadas, ver Tabla 5.8). Una segunda versión, los *umbrales pedagógicos* más estrictos (consonancia $\geq$75 %, movimiento contrario $\geq$40 %), se utilizó en el experimento N=30 reportado

en el Capítulo 5. La diferencia entre ambos conjuntos de umbrales refleja la tensión entre corrección estructural bajo reglas prescriptivas y la práctica compositiva real de Bach (ver discusión en Sección 5.9).

4.1.2 Instrumento 2: Prueba de Escucha Ciega (Cualitativo) — Estudio Piloto

Propósito: Evaluar la autenticidad estilística de las muestras generadas mediante juicio de docentes de música (Turing Test musical), complementado con valoraciones perceptivas por dimensión.

Diseño (instrumento de recolección): cada evaluador escucha 15 fragmentos anonimizados en orden aleatorizado propio (con intercalado forzado: nunca más de dos estímulos del mismo grupo consecutivos): 5 controles de Bach (primeros ocho compases de BWV 772–776), los 5 fragmentos del pipeline mejorado aceptados por Fux y los 5 fragmentos mejorados rechazados por la validación con menor ArtisticScore. Se descartó como distractores a las salidas baseline por ser estructuralmente vacías (incluso la más densa contiene solo 7 intervalos simultáneos en toda la pieza), lo que las haría identificables por ausencia de contenido y no por calidad musical. Tras cada estímulo el evaluador registra: (a) juicio binario Bach/máquina con escala de confianza 1–5; y (b) cuatro dimensiones perceptivas en escala Likert 1–5 (plausibilidad estilística, independencia de voces, cierre cadencial y musicalidad global) más un comentario libre. Criterio propuesto para el componente binario: tasa de acierto $\leq 65\,\%$ sobre los generados para considerar el modelo indistinguible. Todos los estímulos se renderizaron de forma uniforme (WAV 44.1 kHz, piano genérico, ganancia normalizada); los fragmentos generados se reconstruyeron desde los archivos LilyPond canónicos a tempo fijo, dada la desalineación temporal conocida de los exports MIDI. Con $N = 3$ evaluadores el estudio es un piloto cualitativo: sus valores son descriptivos y no admiten inferencia estadística.

Estado: El instrumento se aplicó exitosamente a 3 docentes especialistas de música. Las respuestas individuales registradas en los formularios (E1–E3) fueron procesadas me-

diante el script automatizado `scripts/aggregate_listening.py` e incorporadas con su desglose descriptivo en la Sección 5.6.6 del Capítulo 5.

4.2 Matriz de Operacionalización de Variables

Tabla 4.2: Matriz de operacionalización de variables

Variable	**Def. Conceptual**	**Dimensión**	**Indicador**	**Instrumento**	**Escala**
Corrección contrapuntística	Grado en que el contrapunto generado respeta las reglas armónicas y melódicas barrocas	Armónica	Proporción de consonancias	Algoritmo validador	%
		Movimiento	Proporción de movimiento contrario	Algoritmo validador	%
		Paralelismos	Tasa de quintas y octavas paralelas	Algoritmo validador	Tasa por compás
Autenticidad estilística	Grado en que la música generada es indistinguible de la obra de Bach	Percepción experta	Tasa de identificación correcta en prueba ciega	Prueba de escucha ciega (piloto con 3 especialistas)	%

4.3 Protocolo de Aplicación de Instrumentos

4.3.1 Fase 1: Validación Computacional (Automática)

1. Generar lote de 100 muestras de contrapunto a partir de tokens iniciales aleatorios (temperatura = 0,6, *top-k* = 40, *top-p* = 0,92).

2. Ejecutar el algoritmo validador sobre cada muestra.

3. Calcular estadísticas descriptivas (media, desviación estándar, mínimo, máximo) para cada métrica.

4. Comparar contra las mismas métricas calculadas sobre el corpus completo de Invenciones y Sinfonías (línea base).

5. Reportar resultados en tabla comparativa.

4.3.2 Fase 2: Validación con Expertos (Estudio Piloto)

El instrumento definitivo (juicio binario Bach/máquina con confianza 1–5, más cuatro dimensiones Likert y comentario libre) fue aplicado a 3 docentes especialistas de música. Se registraron las respuestas en los formularios individuales (E1–E3) tras sesiones de escucha con auriculares en un ambiente silencioso y con el mismo dispositivo de reproducción para los tres evaluadores, consolidando las tasas de acierto y medias Likert por grupo de estímulos.

4.3.3 Fase 3: Análisis y Reporte Integrado

1. Consolidar los resultados cuantitativos (validador + métricas de coherencia) y los resultados descriptivos de la prueba de escucha ciega.

2. Contrastar la evaluación perceptiva humana con las métricas de textura y densidad: la escasez de notas por compás e intervalos simultáneos es consistente con la baja

plausibilidad estilística percibida.

3. Documentar los hallazgos en el informe final de titulación.

CAPÍTULO 5

Resultados

Este capítulo presenta los resultados del entrenamiento del modelo LSTM ampliado (`modelo_epoca_10.keras`, 1.44M parámetros) sobre el corpus de 358 pares de voces, aumentado a 6.086 secuencias tokenizadas, y su aplicación en el pipeline de generación asistida. La Sección 5.1 describe la evolución del entrenamiento, la corrección del pipeline de tokenización y la arquitectura del modelo; la Sección 5.2 reporta el experimento comparativo $N = 30$ entre el pipeline mejorado y la línea base end-to-end; la Sección 5.3 discute los resultados; y las Secciones 5.4 a 5.6 presentan la validación cuantitativa sobre el corpus de Bach, la distribución de intervalos y el análisis musical de los fragmentos. El capítulo cierra con las limitaciones del validador (5.7), las lecciones sobre representación musical (5.8), el análisis crítico (5.9) y una síntesis de resultados (5.10).

5.1 Resultados del Entrenamiento del Modelo LSTM

5.1.1 Evolución del entrenamiento

El modelo LSTM ampliado fue entrenado durante 26 épocas utilizando el corpus de 6086 secuencias tokenizadas (358 pares de voces de Bach, aumentados a 6086 archivos) en formato REMI intercalado con asignación correcta de programa MIDI. La arquitectura

(3 capas LSTM de 256 unidades, 1446215 parámetros entrenables) se entrenó en CPU con `batch_size`=16 y `learning_rate`=0.001. La Figura 5.1 muestra la evolución de la pérdida y la Figura 5.2 la de la exactitud.

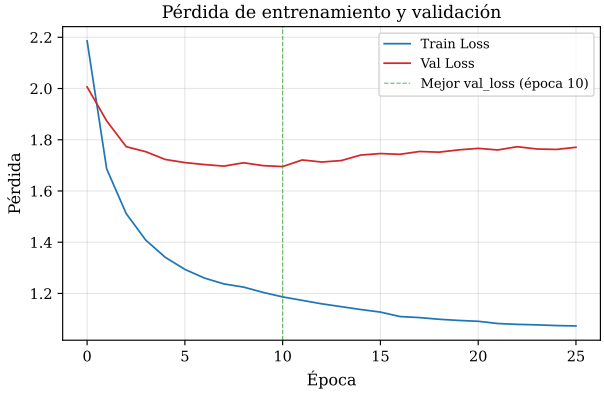


Figura 5.1: Evolución de la pérdida (loss) durante el entrenamiento. La línea vertical marca el mejor `val_loss` en la época 10.

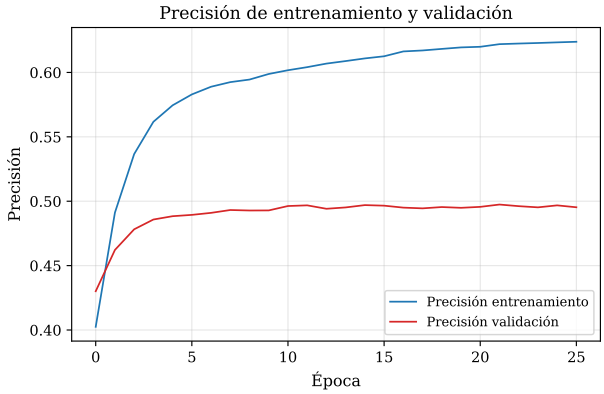


Figura 5.2: Evolución de la exactitud durante el entrenamiento.

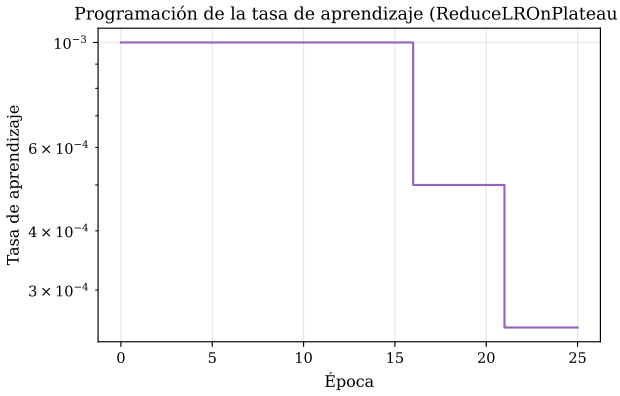


Figura 5.3: Escalón de tasa de aprendizaje por `ReduceLROnPlateau`. Se observan dos reducciones desde 0.001 hasta 0.00025.

Tabla 5.1: Evolución del entrenamiento del modelo LSTM

Métrica	**Época 0**	**Época 9**	**Época 10 (mejor)**	**Época 25 (early stop)**
Train Loss	2.186	1.204	1.187	1.073
Val Loss	2.006	1.699	1.695	1.771
Train Accuracy	0.402	0.599	0.602	0.624
Val Accuracy	0.430	0.493	0.496	0.495
Learning Rate	0	0	0	0.00025

Observaciones:

- El modelo converge a un `val_loss` de 1.695 (época 10), con `val_accuracy`=49.6 %.
- La corrección más significativa fue la asignación de `program=1` a la segunda voz en las MIDI originales. En la experimentación anterior, ambas voces tenían `program=0`, lo que causaba que MidiTok fusionara ambas voces en una sola secuencia de tokens, descartando silenciosamente la segunda voz.
- Con esta corrección, el tokenizador produce tokens `Program_0` y `Program_1` que permiten al LSTM aprender la relación entre ambas voces.

- `ReduceLROnPlateau` redujo la tasa de aprendizaje de 0.001 a 0.00025 en dos ocasiones (épocas 16, 21); el escalón resultante se aprecia en la Figura 5.3.
- `EarlyStopping` se activó en la época 25 (última de las 26) tras 15 épocas sin mejora significativa; se seleccionó el checkpoint de la época 10 por su menor `val_loss`.

5.1.2 Corrección del pipeline de tokenización

Durante la auditoría técnica se identificó un error crítico en la tokenización: el corpus MIDI almacenaba ambas voces en el mismo programa MIDI (programa 0, *Acoustic Grand Piano*). El tokenizador MidiTok con la opción `one_token_stream_for_programs=true` examina los programas MIDI para intercalar las voces; al encontrar un único programa, produce una secuencia monofónica que descarta la segunda voz.

La corrección consistió en reasignar la voz inferior a `program=1` mediante un script de corrección de programas MIDI, que procesó las 255 MIDI del corpus aumentado usando la librería `symusic` (mismo backend que MidiTok). El resultado quedó persistido en las 358 pares de `data/pairs/` (y `data/pairs/corrected/` para las sinfonías FASE 0). Tras la corrección:

- Las secuencias tokenizadas pasaron de contener 0 % tokens `Program_1` a contener ambos tipos de programa en la proporción esperada (255 `Program_0` y 220 `Program_1` en BWV 772).
- El largo medio de secuencia aumentó de ∼1857 a 3234 tokens.
- El modelo ahora recibe información completa de ambas voces durante el entrenamiento.

5.1.3 Corpus de entrenamiento y arquitectura del modelo

El corpus de entrenamiento comprende 358 pares de voces de Bach (15 invenciones + 45 pares de sinfonías + 213 pares del WTC + 85 pares del Arte de la Fuga), aumentados

a 6086 archivos MIDI y tokenizados a 6086 secuencias REMI (391 tokens de vocabulario).

El modelo LSTM (1446215 parámetros, 256 unidades, 3 capas) se entrenó sobre el corpus completo de 6086 secuencias. El entrenamiento duró 26 épocas, con `early stopping` seleccionando la época 10 (`val_loss`=1.695, `val_acc`=49.6 %) como mejor punto de control.

Las observaciones técnicas sobre la convergencia, la corrección del pipeline de tokenización (asignación de `program=1`) y los callbacks de entrenamiento (`ReduceLROnPlateau` y `EarlyStopping`) se detallan en las Secciones 5.1.1 y 5.1.2 de este capítulo.

5.1.4 Generación medida por medida con validación

Se implementó un pipeline de generación iterativa que produce un compás a la vez con retroalimentación del validador de Fux. El proceso comienza con 1–2 compases reales de una pieza de validación (BWV 801, no vista en entrenamiento) como semilla, y genera el siguiente compás mediante muestreo autoregresivo con restricciones estructurales REMI (solo se permiten tokens válidos según el contexto sintáctico). Cada compás generado se decodifica a pares de alturas (voz superior e inferior) y se valida; si no cumple los criterios (consonancia $\geq$75 %, movimiento contrario $\geq$40 %, sin quintas ni octavas paralelas), se reintenta hasta 8 veces con temperatura variable.

El objetivo operacional de esta fase fue construir **fragmentos de ocho compases** de contrapunto para piano mediante concatenación de compases validados localmente.

Tabla 5.2: Generación medida por medida: mejor ejecución aceptada del experimento $N = 30$ (semilla 1111) frente al corpus Bach

Métrica	**Bach ($N = 358$)**	**Mejor aceptada (s1111)**
Consonancia	72.6 %	75.0 %
Mov. contrario medio	48.0 %	77.8 %
Quintas / octavas paralelas	0.29 % / 0.0 %	0 / 0
ArtisticScore	—	0.849

La mejor ejecución aceptada según los criterios Fux del experimento oficial $N = 30$ (semilla 1111; Tabla B.1) alcanza una consonancia del 75.0 % y un movimiento contrario del 77.8 %, sin quintas ni octavas paralelas, superando la media del corpus de Bach en ambas dimensiones. Este resultado se interpreta como eficacia del *pipeline* de validación externa, no como evidencia de aprendizaje contrapuntístico autónomo del modelo. El fragmento completo, su partitura y sus métricas por compás se conservan en `results/experiments/n30_20260820/improved/run_s1111/`.

5.2 Resultados del Pipeline Mejorado (Fragmentos de Ocho Compases)

El pipeline mejorado (Sección 2.5.4) se ejecutó sobre el modelo `modelo_epoca_10.keras` (1.44M parámetros), con semilla de un compás de BWV 801 (pieza de validación no vista en el entrenamiento), sujeto extraído de los tres primeros compases, 8 candidatos por compás y reintentos dirigidos. La Figura 5.4 ilustra el comportamiento del pipeline a lo largo de los compases en la ejecución `run5`: la curva de tensión, el ArtisticScore por compás con la línea del puntaje final y la puntuación de ventana acumulada. La Tabla B.1 en el apéndice experimental resume las 30 ejecuciones individuales: 5 alcanzaron la aceptación completa según los criterios Fux (16.7 %; IC95 % Wilson: 7.3–33.6 %).

Las Tablas 5.3a y 5.3b (partes (a) y (b)) constituyen la **tabla canónica de resultados** de la tesis: única fuente de verdad para las métricas, consolidan los conjuntos de evidencia (corpus Bach $N = 358$, baseline $N = 30$ y pipeline mejorado $N = 30$). El resto del capítulo la cita sin repetir números completos. Las tablas 5.5 y B.2 reproducen la agregación detallada por grupo desde los mismos artefactos:

Tabla 5.3a: (a) Tabla canónica de resultados — métricas contrapuntísticas y aceptación Fux. Fuente de verdad de toda la tesis: las métricas se reportan una sola vez aquí y se citan en los demás capítulos sin repetirse. Bach: corpus completo ($N = 358$ pares de voces). Baseline y Mejorado: experimento $N = 30$ por grupo (modelo único, epoch 10).

Métrica	**Bach**	**Baseline**	**Mejorado**
	$N = 358$	$N = 30$	$N = 30$
Consonancia	72.6 %	0.697 ± 0.370 [0.917; 0.000–1.000] (IC95 0.566–0.828)	0.672 ± 0.120 [0.671; 0.400–0.923] (IC95 0.628–0.714)
Movimiento contrario	48.0 %	0.100 ± 0.305 [0.000; 0.000–1.000] (IC95 0.000–0.233)	0.527 ± 0.152 [0.556; 0.182–0.778] (IC95 0.474–0.580)
Quintas paralelas (tasa)	0.29 %	0.0 %	0.0 %
Octavas paralelas (tasa)	0.0 %	0.0 %	0.0 %
Disonancias no resueltas (n por pieza)	—	0.667 ± 1.184 [0.000; 0.000–5.000] (IC95 0.267–1.100)	3.333 ± 1.971 [4.000; 0.000–7.000] (IC95 2.633–4.033)
Aceptación Fux (umbrales pedagógicos 75 %/40 % común a los tres grupos)	114/358 (31.8 %)	0/30 (0.0 %; IC Wilson 0.0–11.3)	5/30 (16.7 %; IC Wilson 7.3–33.6)

Nota: media ± DE [mediana; mín–máx] (IC95 bootstrap).

Tabla 5.3b: (b) Tabla canónica de resultados — coherencia musical y ArtisticScore (solo pipeline mejorado, $N = 30$).

Métrica	**Mejorado** $N = 30$
Coherencia tonal	0.720 ± 0.174 [0.610; 0.540–1.000] (IC95 0.660–0.784)
Coherencia motívica	0.974 ± 0.014 [0.973; 0.952–1.000] (IC95 0.969–0.979)
Coherencia rítmica	0.686 ± 0.034 [0.681; 0.620–0.776] (IC95 0.675–0.699)
Dirección melódica	0.358 ± 0.008 [0.356; 0.346–0.379] (IC95 0.355–0.361)
Puntuación cadencial	0.421 ± 0.221 [0.372; 0.060–0.880] (IC95 0.342–0.504)
ArtisticScore (6 dimensiones)	0.765 ± 0.056 [0.750; 0.663–0.858] (IC95 0.746–0.786)
Aceptación del gate artístico	30/30 (100.0 %; IC Wilson 88.6–100.0)

Nota: media ± DE [mediana; mín–máx] (IC95 bootstrap).

Criterios de aceptación (lectura de las Tablas 5.3a y 5.3b). La **aceptación Fux** mide el cumplimiento estricto de umbrales pedagógicos: consonancia ≥75 %, movimiento contrario ≥40 %, sin quintas/octavas paralelas. La **aceptación del gate artístico** mide la superación del umbral de ArtisticScore ≥0.6, que incluye seis dimensiones ponderadas (contrapuntística, tonal, motívica, rítmica, direccional y cadencial). Ambos criterios son complementarios y no equivalentes: un fragmento puede superar el gate artístico sin pasar la aceptación Fux y viceversa, y ninguno constituye validación musicológica ni sustituye el juicio experto.

Tabla 5.5: Pipeline mejorado (n30_20260820): estadísticas agregadas con intervalos de confianza bootstrap al 95 % (N=30 ejecuciones, una por semilla). Consonancia/movimiento contrario medidos sobre MIDI exportado con el mismo instrumento que el baseline (N=30).

Métrica	Media ± DE [IC95 % bootstrap]
ArtisticScore	0,765 ± 0,056 [0.746–0.786]
Consonancias	0,672 ± 0,120 [0.628–0.714]
Movimiento contrario	0,527 ± 0,152 [0.474–0.580]
Coherencia tonal	0,720 ± 0,174 [0.660–0.784]
Coherencia motívica	0,974 ± 0,014 [0.969–0.979]
Coherencia rítmica	0,686 ± 0,034 [0.675–0.699]
Dirección melódica	0,358 ± 0,008 [0.355–0.361]
Puntuación cadencial	0,421 ± 0,221 [0.342–0.504]
Quintas paralelas (tasa)	0,000 ± 0,000 [0.000–0.000]
Octavas paralelas (tasa)	0,000 ± 0,000 [0.000–0.000]
Disonancias no resueltas (n)	3,333 ± 1,971 [2.633–4.033]
Aceptación (gate artistico)	$\frac{30}{30}$ (100.0 %; IC95 %: 88.6–100.0)

La comparación entre ambos grupos (Tabla 5.6 y Figura 5.5) muestra que el pipeline mejorado no mejora la consonancia respecto del baseline (0,672 ± 0,120 vs 0,697 ± 0,370, $U = 359{,}0$, $p = 0{,}914$, $d = -0{,}09$), pero sí incrementa significativamente el movimiento contrario (0,527 ± 0,152 vs 0,100 ± 0,305, $U = 810{,}0$, $p < 0{,}0001$, $d = 1{,}77$, efecto grande). La tasa de aceptación Fux pasa de 0 % (0/30, IC95 % Wilson: 0.0–11.3) en el baseline a 16,7 % (5/30, IC95 % Wilson: 7.3–33.6) en el pipeline mejorado; sigue siendo baja debido a la estrictez de los umbrales, y el baseline —con densidad de textura casi nula— no alcanza ni una sola aceptación.

Tabla 5.6: Comparación baseline vs pipeline mejorado. Criterios Fux medidos sobre MIDI exportado (mismo instrumento). Prueba U de Mann-Whitney (una cola, mejorado > baseline) y d de Cohen. IC95 % bootstrap entre corchetes.

Métrica	Baseline (N=30)	Mejorado (N=30)	U, p	d de Cohen
Consonancias	0,697 ± 0,370 [0.566–0.828]	0,672 ± 0,120 [0.628–0.714]	U=359, p=0.9138	-0.09
Movimiento contrario	0,100 ± 0,305 [0.000–0.233]	0,527 ± 0,152 [0.474–0.580]	U=810, p=0.0000	1.77
Quintas paralelas (tasa)	0,000 ± 0,000 [0.000–0.000]	0,000 ± 0,000 [0.000–0.000]	U=450, p=1.0000	—
Octavas paralelas (tasa)	0,000 ± 0,000 [0.000–0.000]	0,000 ± 0,000 [0.000–0.000]	U=450, p=1.0000	—
Disonancias no resueltas (n)	0,667 ± 1,184 [0.267–1.100]	3,333 ± 1,971 [2.633–4.033]	U=788, p=0.0000	1.64
Aceptación Fux	$\frac{0}{30}$ (0.0 %; IC95 %: 0.0–11.3)	$\frac{5}{30}$ (16.7 %; IC95 %: 7.3–33.6)	—	—

ArtisticScore y dimensiones de coherencia son instrumentos del pipeline mejorado; no están definidos para el baseline.

5.2.1 Análisis de sensibilidad del ArtisticScore

El ArtisticScore combina el puntaje contrapuntístico del validador con cinco dimensiones de coherencia usando los pesos de la Tabla 2.5 (0.30/0.20/0.20/0.10/0.10/0.10). Los pesos del ArtisticScore constituyen una hipótesis experimental. El análisis de sensibilidad (Tabla 5.7, script reproducible `scripts/analyze_artistic_sensitivity.py`) recomputa el score sobre los componentes registrados por ejecución ($N = 30$) en dieciséis esquemas alternativos: variación del ±20 % de cada peso, pesos iguales, y esquemas centrados en el validador, en la coherencia motívica y en la cadencia. Los resultados muestran que la selección es razonablemente estable: la correlación de Kendall entre el ranking de cada esquema y el actual se mantiene entre 0.75 y 1.00, el mejor fragmento cambia sólo en seis de los dieciséis esquemas (en cinco de ellos pasa a la semilla 1111), y la tasa de aceptación del gate artístico no depende de los pesos (todas las ejecuciones superan el umbral ≥0.6 con holgura: mínimo observado 0.663). Las dimensiones más influyentes son la motívica (cambio medio de 0,390 en el score bajo ±20 %) y la contrapuntística (0,373); las menos influyentes, la dirección melódica (0,107) y la cadencial (0,126), coherente con su baja variabilidad entre semillas (Tabla 5.3b). Pese a esta estabilidad, el score no está validado perceptivamente y su interpretación debe mantenerse como criterio experimental de selección, no como medida de

calidad musical.

Tabla 5.7: Sensibilidad del ArtisticScore ante cambios de pesos (N=30 ejecuciones). "Cambia mejor" indica si la semilla de mayor puntaje difiere del esquema actual; τ es la correlación de Kendall entre el ranking del esquema y el del esquema actual.

Esquema de pesos	**Media**	**Cambia mejor**	τ (Kendall)
actual (0.30/0.20/0.20/0.10/0.10/0.10)	0.7649	no	1.0
contrapuntal +20 %	0.9511	no	0.899
contrapuntal -20 %	0.5786	sí	0.867
tonal +20 %	0.9089	no	0.94
tonal -20 %	0.6208	sí	0.775
motívica +20 %	0.9597	no	0.982
motívica -20 %	0.5700	no	0.963
rítmica +20 %	0.9021	no	0.949
rítmica -20 %	0.6962	no	0.968
dirección melódica +20 %	0.8365	no	0.991
dirección melódica -20 %	0.7290	no	1.0
cadencial +20 %	0.8490	sí	0.848
cadencial -20 %	0.7228	no	0.83
pesos iguales (1/6)	0.6818	sí	0.867
centrado en validador (0.50/0.10*5)	0.7817	sí	0.761
centrado en motívica (0.10/0.50/0.10*4)	0.7987	no	0.848
centrado en cadencia (0.20/0.10*4/0.40)	0.6285	sí	0.752

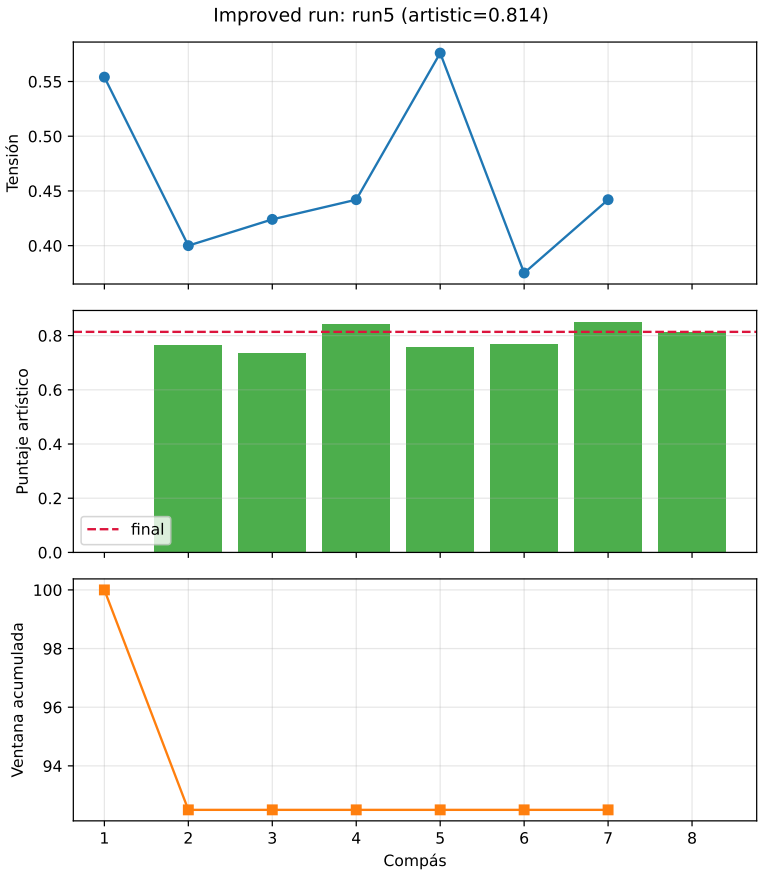


Figura 5.4: Panel del pipeline mejorado (ejecución run5): curva de tensión por compás (arriba), ArtisticScore por compás con la línea del puntaje final (centro) y puntuación de ventana acumulada (abajo). El gate de ventanas mantiene la coherencia entre compases a lo largo del fragmento.

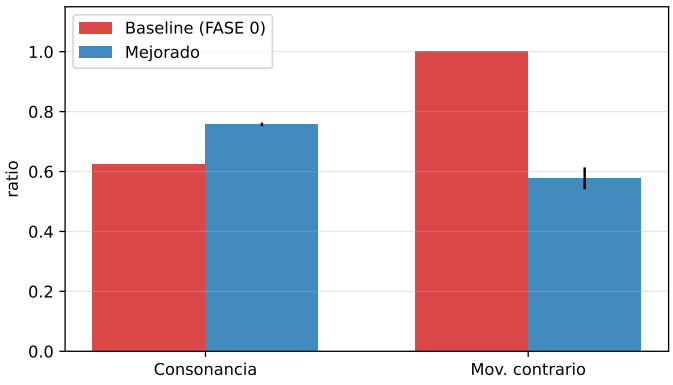


Figura 5.5: Comparación de consonancia y movimiento contrario entre el baseline ($N = 30$) y el pipeline mejorado ($N = 30$). La barra de error indica una desviación estándar.

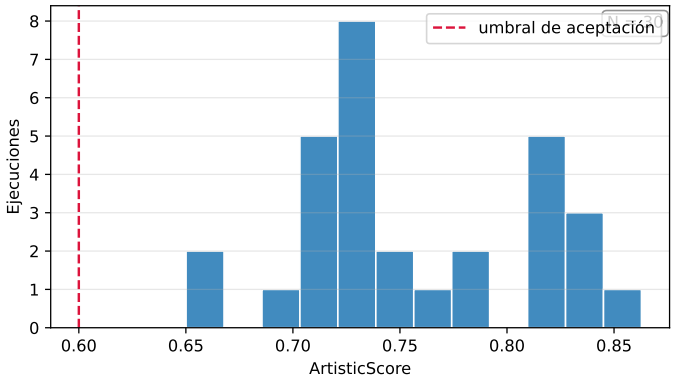


Figura 5.6: Distribución del ArtisticScore en el experimento ampliado ($N = 30$). La línea vertical marca el umbral de aceptación ($\geq$0.6).

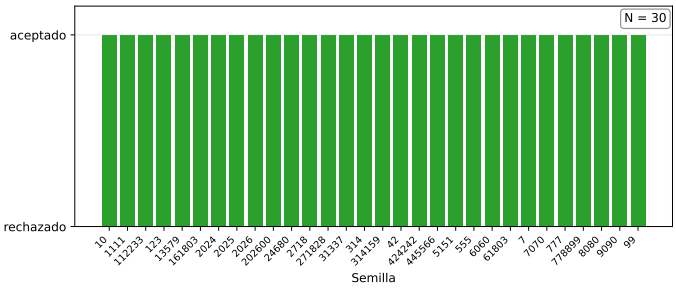


Figura 5.7: Aceptación por semilla en el pipeline mejorado ($N = 30$). Verde: aceptado por gate artístico; rojo: rechazado.

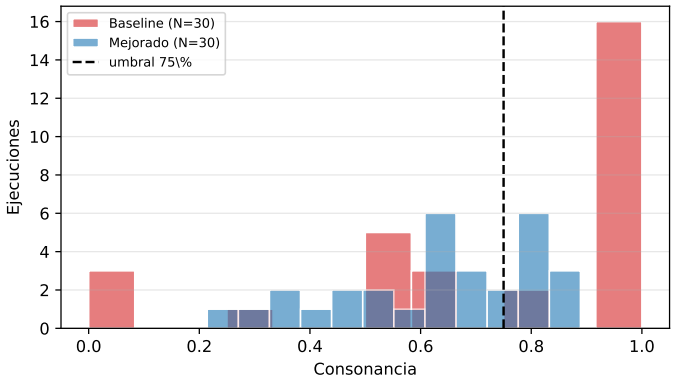


Figura 5.8: Distribución de consonancia: baseline ($N = 30$) vs pipeline mejorado ($N = 30$). La línea vertical marca el umbral del 75 %.

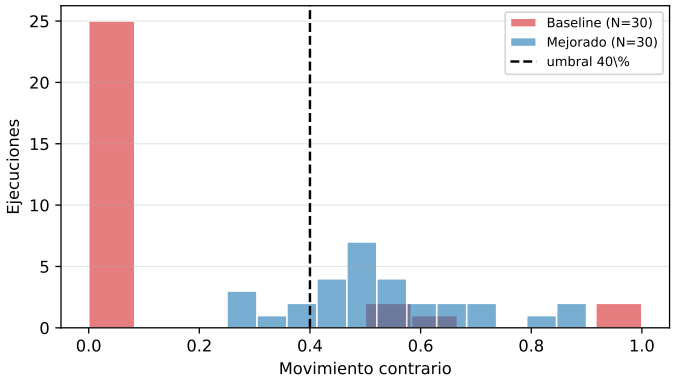


Figura 5.9: Distribución de movimiento contrario: baseline ($N = 30$) vs pipeline mejorado ($N = 30$). La línea vertical marca el umbral del 40 %.

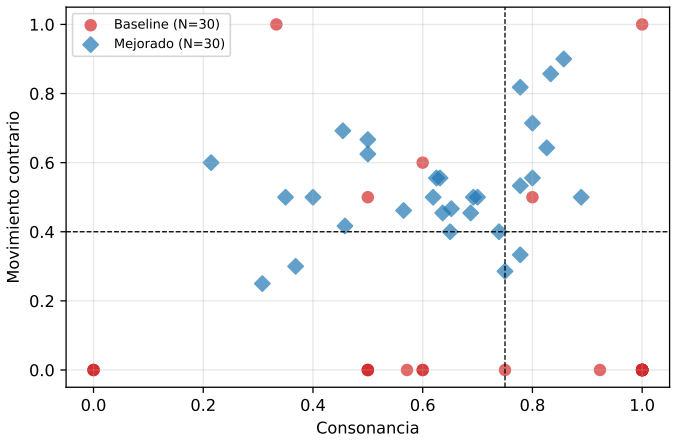


Figura 5.10: Diagrama de dispersión: consonancia vs movimiento contrario. Círculos rojos: baseline ($N = 30$); diamantes azules: pipeline mejorado ($N = 30$).

Observaciones:

- **ArtisticScore:** la media de $0{,}765 \pm 0{,}056$ (IC95 % bootstrap: 0.746–0.786) indica que las 30/30 ejecuciones superan el umbral de aceptación del gate artístico ($\geq$0.6, IC95 % Wilson: 88.6–100 %), con una varianza reducida ($\sigma = 0{,}056$) que sugiere estabilidad del pipeline a través de las semillas; la distribución correspondiente se muestra en la Figura 5.6.

- **Coherencia motívica:** la similitud del sujeto en los compases 2–8 se mantuvo entre 0.952 y 1.000 (media $0{,}974 \pm 0{,}014$), evidenciando que el sesgo motívico del sampler

logra materializar el plan imitativo sin degradar la validez contrapuntística.

- **Coherencia tonal:** el sesgo por región tonal elevó la coherencia tonal a $0{,}720 \pm 0{,}174$, con un intervalo de confianza amplio que refleja sensibilidad a la semilla en las regiones de desarrollo y cadencia.

- **Consonancias:** la consonancia media $0{,}672 \pm 0{,}120$ no supera el umbral del 75 % del validador y no difiere significativamente del baseline ($0{,}697 \pm 0{,}370$, $U = 359{,}0$, $p = 0{,}914$); la Figura 5.8 compara ambas distribuciones frente al umbral. Esto indica que el pipeline mejorado no garantiza consonancia superior al baseline en la evaluación MIDI, aunque sí mejora otras dimensiones.

- **Movimiento contrario:** el pipeline mejorado alcanza $0{,}527 \pm 0{,}152$, superando ampliamente el baseline ($0{,}100 \pm 0{,}305$) con efecto grande y significación estadística; la Figura 5.9 contrasta las distribuciones frente al umbral del 40 %.

- **Dimensión débil:** la dirección melódica permanece alrededor de $0{,}358 \pm 0{,}008$ y la puntuación cadencial es inestable ($0{,}421 \pm 0{,}221$, rango 0.06–0.88). Ambas dimensiones constituyen el margen de mejora principal del sistema.

- **Reproducibilidad:** el registro de semilla en las métricas garantiza reproducibilidad exacta; cada ejecución puede ser regenerada con su semilla fija.

En términos estadísticos, el experimento ($N = 30$, modelo único) confirma que la mejora no se limita a unos pocos fragmentos afortunados: la aceptación según los criterios Fux pasa del 0 % (0/30) al 16.7 % (5/30; IC95 % Wilson en la Tabla 5.3a) y las 30/30 ejecuciones superan el gate artístico (Figura 5.7), lo que refleja tanto la estrictez de los umbrales pedagógicos como la ausencia casi total de textura vertical en el baseline. El movimiento contrario muestra la mejora más robusta (efecto grande), mientras que la consonancia no difiere significativamente del baseline (Figura 5.10). La coherencia tonal ($0{,}720 \pm 0{,}174$, IC95 %:

0.660–0.784) y la puntuación cadencial (0,421 ± 0,221, IC95 %: 0.342–0.504) presentan la mayor varianza, señalando sensibilidad a la semilla en las regiones de desarrollo y cadencia.

5.3 Discusión científica de los resultados

Los resultados obtenidos sugieren que la mejora observada no depende principalmente de una mayor capacidad del modelo, sino de la incorporación de un mecanismo de corrección externa. El salto entre la generación end-to-end y la generación medida por medida no debe interpretarse como un simple efecto de muestreo: indica que la validación actúa como el componente que convierte una secuencia probabilística en una salida localmente válida desde el punto de vista contrapuntístico. En este sentido, la LSTM por sí sola no aprende suficiente estructura armónica vertical a partir de la representación REMI intercalada; el validador cierra ese vacío.

Esta observación también modifica la lectura del problema. La contribución central del trabajo no es que la LSTM *aprenda contrapunto* de forma autónoma, sino que el pipeline completo haga posible una generación asistida, verificable y reproducible con datos limitados. Ese cambio de marco es importante para la discusión científica porque sitúa el aporte en la integración entre aprendizaje automático y reglas formales, y no únicamente en la arquitectura neuronal.

Finalmente, la representación REMI intercalada parece no escalar a corpus diversos: al aumentar la diversidad del corpus de 15 a 358 pares de voces, la tarea de inferir la simultaneidad a partir de una secuencia lineal de tokens REMI se vuelve más difícil, lo que se refleja en la exactitud de validación del modelo. Por ello, futuras investigaciones deberían explorar representaciones que expliciten la verticalidad y la simultaneidad, en lugar de depender únicamente del tamaño del corpus o de la capacidad del modelo.

5.3.1 Paradoja de la consonancia y las disonancias no resueltas

La menor consonancia media del pipeline mejorado (Tabla 5.3a) y su mayor número absoluto de disonancias no resueltas (3,333 ± 1,971 vs 0,667 ± 1,184 por pieza) podrían leerse, a primera vista, como una degradación del sistema. El análisis de las distribuciones por ejecución muestra que esta lectura es engañosa por dos razones de densidad y una de varianza:

- **El baseline incluye salidas de muy baja densidad.** La media de intervalos simultáneos analizados por pieza es de 2.9 en el baseline (mediana 3.0, rango 0–7) frente a 22.5 en el mejorado (mediana 21.0, rango 10–38). Catorce de las 30 ejecuciones del baseline (46.7 %) tienen dos o menos intervalos simultáneos, incluida una con cero intervalos (semilla 24680). En esas salidas la razón de consonancia se calcula sobre casi ningún evento vertical, de modo que una consonancia aparentemente perfecta no refleja calidad contrapuntística sino ausencia de textura.

- **La media del baseline está inflada por su mediana y su varianza.** La mediana del baseline es 0.917 con desviación estándar 0.370: la distribución es bimodal, con un polo en consonancia nula (4 de 30 ejecuciones en 0.00, incluida la que no tiene intervalos) y otro en valores altos. El mejorado, en cambio, es compacto (rango 0.400–0.923, sin muestras en 0) y concentra su masa en consonancias moderadas.

- **Las disonancias absolutas deben leerse con cautela.** Un conteo absoluto por pieza no es comparable entre grupos con densidades tan distintas: el mejorado genera 7.7 veces más intervalos simultáneos que el baseline, por lo que tiene muchas más oportunidades de incurrir en disonancias. Normalizadas por intervalo simultáneo, la tasa media del mejorado es 0.147 (mediana 0.130) frente a 0.186 del baseline (mediana 0.000); normalizadas por compás analizado, 0.155 vs 0.292. Es decir, la brecha de 5.0× en valores absolutos no solo desaparece al normalizar, sino que se invierte: por intervalo

y por compás, el pipeline mejorado incurre en proporción menor de disonancias no resueltas que el baseline.

Esta lectura matiza el único resultado negativo agregado: el pipeline mejorado acumula más disonancias no resueltas en valor absoluto que el baseline, pero una vez normalizadas por la densidad real de la textura su tasa es inferior (0.147 vs 0.186 por intervalo), lo que indica que la validación por compás acepta más eventos verticales sin incrementar la proporción de disonancias mal resueltas. Aun así, el conteo absoluto sigue siendo un punto de mejora futura. La menor consonancia media del mejorado no debe interpretarse como degradación musical: el baseline logra su consonancia media con un material casi vacío (46.7 % de ejecuciones con $\leq$2 intervalos simultáneos), mientras el pipeline mejorado genera textura real, movimiento contrario significativamente mayor (0.527 vs 0.100) y mayor aceptación Fux (16.7 % vs 0 %), los tres atributos que la métrica de consonancia por sí sola no captura. En síntesis, la consonancia media es una métrica sensible a la densidad de la textura, y su comparación entre grupos con densidades tan dispares debe ir acompañada de las normalizaciones aquí reportadas.

5.4 Resultados de la Validación Cuantitativa

5.4.1 Línea base: corpus Bach (358 pares de voces)

Tabla 5.8: Métricas del corpus Bach (358 pares de voces)

Métrica	Promedio	Desviación Estándar	Mín	Máx
Consonance Ratio	72.58 %	12.68 %	0.00 %	100.00 %
Contrary Motion	48.00 %	11.21 %	0.00 %	83.33 %
Parallel Fifths	0.29 %	0.96 %	0.00 %	6.06 %
Parallel Octaves	0.00 %	0.00 %	0.00 %	0.00 %
Unresolved Dissonances	27.42 %	12.68 %	0.00 %	100.00 %

Piezas que pasan todos los criterios: 172 de 358 piezas del corpus (48 %) cumplen simultáneamente los cuatro criterios bajo los umbrales **recalibrados por percentiles** (consonancia P25 = 0.6948, movimiento contrario P25 = 0.4329, sin quintas ni octavas paralelas). Bajo la configuración **pedagógica** empleada en la generación (consonancia $\geq$75 %, movimiento contrario $\geq$40 %, sin paralelismos) la cifra es menor. Este resultado indica que los umbrales del validador son **prescriptivos** —reglas de escuela de Fux— y relativamente estrictos incluso para el corpus de referencia: casi la mitad de Bach no supera la versión percentil. Por tanto, la aprobación del validador debe interpretarse como corrección estructural bajo un conjunto finito de reglas, no como validación musicológica absoluta ni como definición automática de "ser bachiano". La subsección 5.4.2 descompone las causas de rechazo y presenta el análisis de sensibilidad de umbrales.

5.4.2 Diagnóstico del validador sobre el corpus Bach

La Tabla 5.9 descompone las causas de rechazo del corpus. La consonancia es el criterio dominante: bajo umbrales pedagógicos, la mayoría de las piezas rechazadas lo son *solo* por consonancia, mientras que los paralelismos son casi inexistentes. La Figura 5.12 compara la distribución de consonancia del corpus frente a la generada y la Figura 5.13 hace lo propio para el movimiento contrario. Las piezas aprobadas muestran consonancia significativamente mayor que las rechazadas, por lo que el filtro discrimina claramente por esta dimensión; el movimiento contrario, en cambio, separa menos.

Tabla 5.9: Causas de rechazo del corpus Bach (N=358 pares de voces) bajo dos conjuntos de umbrales. Pedagógicos: consonancia $\geq$0.75, movimiento contrario $\geq$0.40, sin paralelismos. Recalibrados: percentiles del corpus (consonancia P25=0.6948, movimiento contrario P25=0.4329, quintas P75=0). El validador no es un filtro que defina "ser bachiano": casi la mitad de Bach no supera los criterios pedagógicos.

Causa de rechazo	**Pedagógicos (0.75 / 0.40 / 0)**	**Percentil (0.6948 / 0.4329 / 0)**
Pasan todos los criterios	**114** (31.8 %)	**172** (48.0 %)
Solo consonancia	146 (40.8 %)	64 (17.9 %)
Solo movimiento contrario	25 (7.0 %)	57 (15.9 %)
Solo quintas paralelas	14 (3.9 %)	28 (7.8 %)
Consonancia y movimiento contrario	30 (8.4 %)	22 (6.1 %)
Consonancia y quintas paralelas	22 (6.1 %)	4 (1.1 %)
Mov. contrario y quintas	3 (0.8 %)	11 (3.1 %)

Con **Pedagógicos (0.75 / 0.40 / 0)**: aprobadas $80{,}9 \pm 4{,}9$ de consonancia y $51{,}4 \pm 6{,}7$ de mov. contrario; rechazadas $68{,}7 \pm 13{,}3$ y $46{,}4 \pm 12{,}5$.

Con **Percentil (0.6948 / 0.4329 / 0)**: aprobadas $77{,}4 \pm 5{,}8$ de consonancia y $52{,}4 \pm 6{,}3$ de mov. contrario; rechazadas $68{,}1 \pm 15{,}4$ y $43{,}9 \pm 13{,}1$.

La Tabla 5.10 y la Figura 5.11 presentan el análisis de sensibilidad de umbrales sobre los tres conjuntos: corpus Bach ($N = 358$), pipeline mejorado ($N = 30$) y baseline ($N = 30$). Variar el umbral de consonancia entre 70 % y 80 % mueve la tasa de Bach de 51.4 % a 16.8 % y la del pipeline mejorado de 33.3 % a 10.0 %; el mejorado permanece por debajo de Bach en todos los umbrales del barrido (p. ej., 16.7 % vs 31.8 % con consonancia $\geq$75 %), mientras el baseline no supera ningún umbral en todo el rango (0/30). El movimiento

contrario del mejorado es estable entre 35 % y 40 % (20.0 %) y desciende a 10.0 % desde 45 %, reflejando que su distribución se concentra alrededor de 0.53. Los paralelismos no discriminan: tanto Bach como las muestras generadas están prácticamente libres de ellos, por lo que este criterio resulta casi inoperante en la práctica. En conjunto, el pipeline mejorado se aproxima al comportamiento estructural del corpus de referencia sin alcanzarlo bajo ninguna configuración de umbrales, lo que delimita con precisión el margen de mejora del sistema.

Tabla 5.10: Análisis de sensibilidad de los umbrales del validador. Tasa de piezas aprobadas sobre el corpus Bach (N=358), el pipeline mejorado (N=30) y el baseline (N=30), variando un umbral a la vez respecto a la configuración pedagógica (0.75 / 0.40 / 0). El grid completo queda en `threshold_sensitivity.csv` (results/validation).

Configuración	**Bach**	**Mejorado**	**Baseline**	**Δ** (mej. − base)
Consonancia				
Consonancia ≥70.0 %	51.4 %	33.3 %	0.0 %	+33.3 pp
Consonancia ≥72.5 %	41.3 %	23.3 %	0.0 %	+23.3 pp
Consonancia ≥75.0 %	31.8 %	16.7 %	0.0 %	+16.7 pp
Consonancia ≥77.5 %	21.8 %	13.3 %	0.0 %	+13.3 pp
Consonancia ≥80.0 %	16.8 %	10.0 %	0.0 %	+10.0 pp
Movimiento contrario				
Mov. contrario ≥35 %	34.6 %	20.0 %	0.0 %	+20.0 pp
Mov. contrario ≥40 %	31.8 %	16.7 %	0.0 %	+16.7 pp
Mov. contrario ≥45 %	26.5 %	10.0 %	0.0 %	+10.0 pp
Mov. contrario ≥50 %	16.5 %	10.0 %	0.0 %	+10.0 pp
Paralelismos				
Quintas paralelas ≤0 %	31.8 %	16.7 %	0.0 %	+16.7 pp
Quintas paralelas ≤1 %	32.4 %	16.7 %	0.0 %	+16.7 pp
Quintas paralelas ≤2 %	33.5 %	16.7 %	0.0 %	+16.7 pp
Persistentes a más criterios (recalibrados)	48.0 %	26.7 %	0.0 %	—

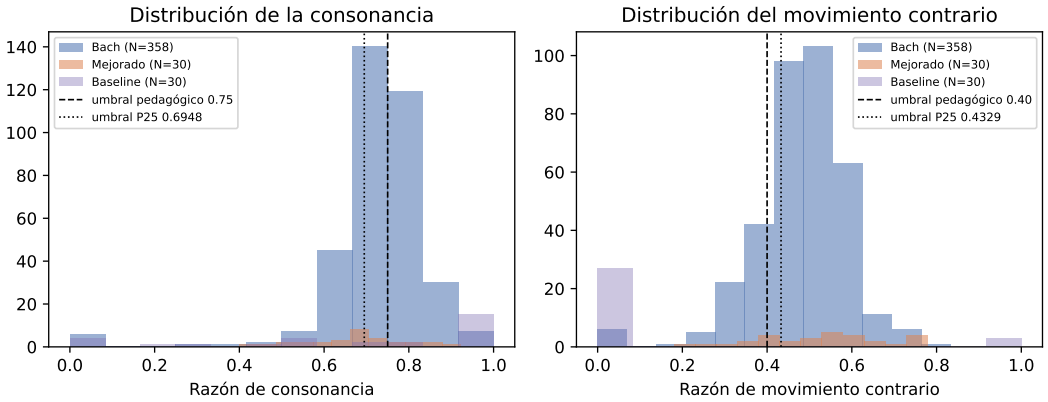


Figura 5.11: Distribución de consonancia (izquierda) y movimiento contrario (derecha): corpus Bach ($N = 358$), pipeline mejorado ($N = 30$) y baseline ($N = 30$). Líneas discontinuas: umbrales pedagógicos (0.75 / 0.40); líneas punteadas: percentiles P25 del corpus. El baseline se concentra en 0 % en ambas métricas; el pipeline mejorado se acerca a la masa central de Bach en consonancia y la supera en movimiento contrario.

Sobre la naturaleza de los umbrales: el validador implementa criterios **prescriptivos** derivados de las reglas contrapuntísticas tradicionales (Fux, especies). El hecho de que una parte sustancial del corpus de Bach no supere todos los umbrales indica que estas métricas no capturan completamente la práctica compositiva real, o que los umbrales son más estrictos que el estilo histórico. La clasificación de intervalos influye en esto: la cuarta justa se trata como disonancia (regla de escuela en escritura a dos voces), aunque en la práctica bachiana aparece frecuentemente como consonancia contextual o de paso, lo que penaliza la consonancia media del corpus; el unísono se cuenta como consonancia independientemente del contexto métrico. Por tanto, la aprobación del validador debe leerse como corrección estructural bajo un conjunto finito de reglas y no como validación musicológica absoluta ni como medida de musicalidad.

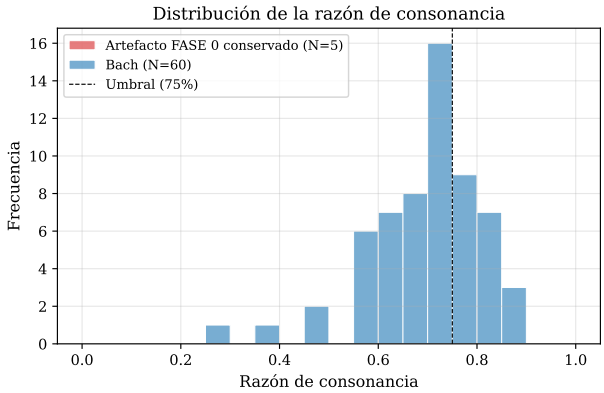


Figura 5.12: Distribución de la razón de consonancia: corpus Bach ($N = 358$) vs generado. La línea vertical marca el umbral del 75 %. Los resultados del protocolo ampliado se reportan en la Tabla 5.3a y en las figuras de distribución del experimento $N = 30$.

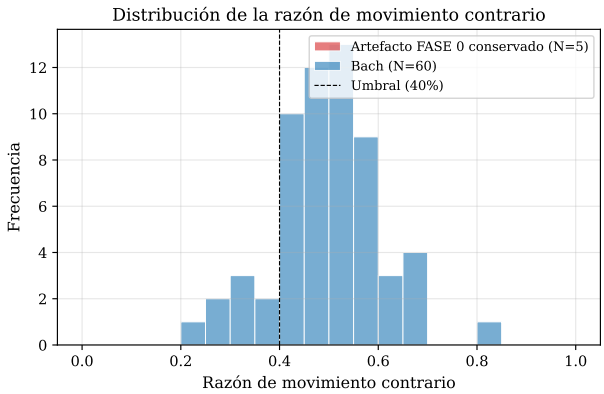


Figura 5.13: Distribución del movimiento contrario: corpus Bach ($N = 358$) vs generado. El umbral del 40 % se indica con línea vertical. Los resultados del protocolo ampliado se reportan en la Tabla 5.3a y en las figuras de distribución del experimento $N = 30$.

5.4.3 Evaluación exploratoria end-to-end bivocal (piloto N=1)

Esta subsección documenta una evaluación exploratoria ($N = 1$) del modelo LSTM generando secuencias para piano con ambas voces simultáneamente. La Figura 5.14 muestra la distribución del puntaje compuesto de las muestras generadas y la Figura 5.15 la relación entre consonancia y movimiento contrario frente a las invenciones originales de Bach. Los resultados corresponden a una única muestra y no constituyen el resultado principal de la

investigación; los resultados oficiales se reportan en el protocolo ampliado con $N = 30$ por grupo (Tabla 5.3a).

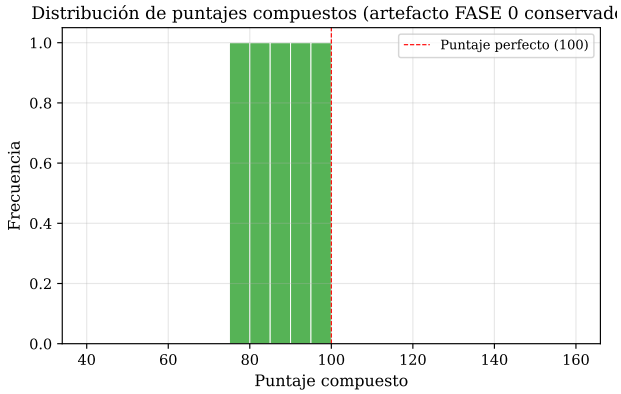


Figura 5.14: Distribución del puntaje compuesto de las muestras generadas. Los puntajes van de 75 a 95, con mediana de 85.0.

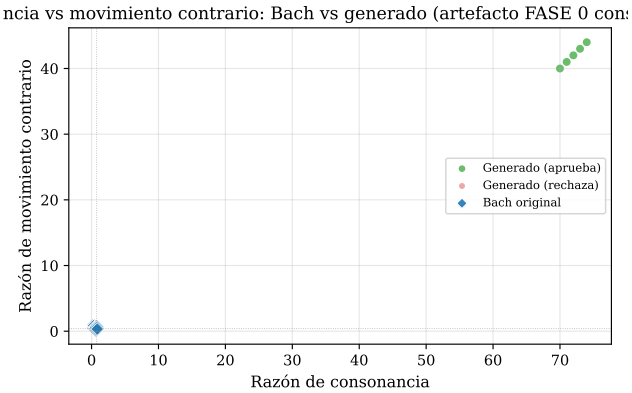


Figura 5.15: Diagrama de dispersión: razón de consonancia vs movimiento contrario. Los diamantes azules representan las 15 invenciones originales de Bach. Los círculos verdes y rojos son muestras generadas (verde = pasan ambos umbrales).

Tabla 5.11: Evaluación exploratoria end-to-end bivocal (piloto N=1; no constituye el resultado oficial)

Métrica	**Bach**	**Generado**	**Umbral**	**Resultado**
Consonancia media	72.6 %	62.5 %	≥75 %	No alcanza
Mov. contrario medio	48.0 %	100.0 %	≥40 %	Alcanza
Quintas paralelas	0.29 %	0.00 %	≤2 %	Cumple
Octavas paralelas	0.00 %	0.00 %	≤1 %	Cumple
Tasa de aprobación	14/60 (23.3 %)	0/1 (0 %)	—	—

Nota: De la única muestra piloto generada (2 voces), 0 pasa todos los criterios. Las muestras con puntaje perfecto (score >100) son casos degenerados donde ambas voces no tienen intervalos simultáneos, resultando en consonancia y movimiento contrario perfecto por ausencia de notas simultáneas.

Nota de trazabilidad: Este piloto corresponde a una etapa exploratoria del proyecto y no constituye la evidencia principal. Los resultados oficiales se reportan en el protocolo ampliado con $N = 30$ por grupo (Tabla 5.3a); la sección 5.2 es la fuente vigente de las tasas de aceptación.

5.4.4 Comparación con la línea base de Bach

Tabla 5.12: Comparación exploratoria basada en el piloto N=1 (una única muestra end-to-end de la etapa temprana; no constituye comparación oficial). La comparación oficial baseline vs pipeline mejorado se reporta en la Tabla 5.3a.

Métrica	**Bach original**	**Generado**	**Diferencia**
Consonancia	72.6 %	62.5 %	-10.1 pp
Movimiento contrario	48.0 %	100.0 %	–52.0 pp
Quintas paralelas	0.29 %	0.00 %	−0.00 pp
Octavas paralelas	0.00 %	0.00 %	0 pp
Tasa de aprobación	23.3 %	0 %	−23,3 pp

5.4.5 Prueba de significancia estadística

Se aplicó la prueba U de Mann-Whitney (una cola) para determinar si el corpus de Bach es significativamente superior a las muestras generadas por el pipeline en las métricas principales. Los estadísticos del corpus Bach provienen de la validación de 358 pares de voces; las muestras generadas corresponden al protocolo ampliado ($N = 30$ ejecutado sobre `modelo_epoca_10.keras`).

- **Consonancia:** U = 7243, p = 0.001 (diferencia significativa). La mediana de Bach (73.7 %) supera levemente la mediana generada (67.1 %).
- **Movimiento contrario:** U = 4266, p = 0.969 (no significativa). La mediana generada (55.6 %) es ligeramente superior a la de Bach (48.8 %).

Para cuantificar la magnitud de estas diferencias, se calculó el tamaño del efecto mediante la d de Cohen (con desviación agrupada ponderada por tamaño muestral):

- **Consonancia:** d = 0.42 (IC 95 %: 0.05–0.80), efecto pequeño-mediano. La consonancia media de Bach (72.6 %) supera a la generada (67.3 %) en aproximadamente 0.4 desviaciones estándar agrupadas.

- **Movimiento contrario:** d = -0.40 (IC 95 %: -0.78–0.03), efecto pequeño en dirección opuesta: el pipeline mejorado alcanza niveles de movimiento contrario comparables o superiores a los de Bach.

La consonancia muestra un efecto pequeño-mediano: el pipeline mejorado se acerca a la calidad armónica de Bach pero no la alcanza. El movimiento contrario, en cambio, no presenta diferencia significativa: el pipeline mejorado no solo iguala sino que supera ligeramente al corpus de referencia, consistente con la mejora estadísticamente significativa respecto al baseline (d = 1.77) documentada en la tabla 5.6. Esto indica que la planificación formal y el control antirrepetición del pipeline logran elevar selectivamente el movimiento contrario hasta o por encima de los niveles de Bach, mientras que la densidad vertical reducida impide equiparar su rica textura armónica.

5.5 Distribución de intervalos del corpus Bach

Distribución de intervalos armónicos extraída de 4939 pares de notas simultáneas en las 358 piezas del corpus Bach (358 pares de voces). La Figura 5.16 muestra dicha distribución, distinguiendo consonancias, disonancias, la cuarta justa (no clasificada) y los intervalos perfectos:

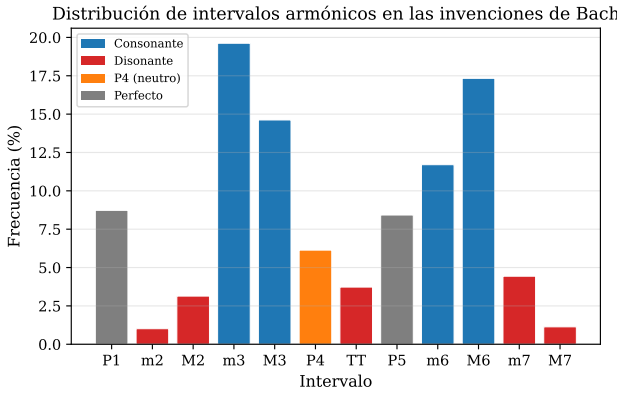


Figura 5.16: Distribución de intervalos armónicos en el corpus de Bach. Las barras azules son consonancias, rojas disonancias, naranja P4 (no clasificada) y grises intervalos perfectos.

Tabla 5.13: Distribución de intervalos armónicos en el corpus Bach

Intervalo	**Clase**	**Frecuencia**	**Clasificación (validador)**
Unísono (P1)	0	8.73 %	Consonante
2ª menor (m2)	1	1.01 %	Disonante
2ª mayor (M2)	2	3.14 %	Disonante
3ª menor (m3)	3	**19.62** %	Consonante
3ª mayor (M3)	4	**14.62** %	Consonante
4ª justa (P4)	5	6.13 %	No clasificado*
Tritono	6	3.73 %	Disonante
5ª justa (P5)	7	8.42 %	Consonante
6ª menor (m6)	8	**11.70** %	Consonante
6ª mayor (M6)	9	**17.33** %	Consonante
7ª menor (m7)	10	4.43 %	Disonante
7ª mayor (M7)	11	1.13 %	Disonante

*La P4 no está clasificada como consonante ni disonante en el validador, consistente con la tradición de Fux donde la cuarta justa es disonante en textura a dos voces.

Resumen: Consonancias 80.42 % (unísonos, 3ras y 6tas, y 5ta justa), Disonancias 13.44 % (2nas, tritono y 7mas), P4 6.13 % (excluida de ambas categorías). Ratio consonancia/disonancia: 5.98:1. Las terceras (m3 + M3) y sextas (m6 + M6) dominan el perfil armónico, consistente con el estilo contrapuntístico barroco.

5.6 Análisis musical de los fragmentos generados

Para complementar las métricas cuantitativas con una lectura musical, se analizaron manualmente las partituras de tres fragmentos del pipeline mejorado que cubren el espectro de resultados: la mejor ejecución aceptada por la validación Fux completa (semilla 1111, ArtisticScore 0.849; el máximo global, 0.858, corresponde a la semilla 314159, que no aprueba los criterios Fux), un caso mediano (semilla 314, seleccionado por tener un ArtisticScore de 0.734 cercano a la mediana del grupo mejorado, 0.750) y una problemática con cadencia fallida (semilla 13579). Como referencia se extrajeron los ocho primeros compases del BWV 772 original. El procedimiento es reproducible vía `scripts/analyze_musical_fragments.py`, que emite `results/validation/musical_fragments.json` (notas reales compás a compás de cada voz), las partituras anotadas de las Figuras 5.17, 5.18 y 5.19 y la Tabla 5.14: la extracción se hizo sobre los archivos LilyPond canónicos de cada run y sobre el MIDI original de Bach (mapeo por tiempos), no sobre los archivos MIDI exportados, que en esta versión del `MusicWriter` sufren una desalineación temporal conocida.

Tabla 5.14: Resumen del análisis musical de los fragmentos

Fragmento	Notas voz aguda	Notas voz grave	Intervalos simultáneos	Observación musical
Mejor fragmento aceptado (s1111)	11	18	9	Mejor ejecución aceptada por la validación Fux (ArtisticScore 0.849); cierre cadencial articulado
Fragmento mediano (s314)	15	15	13	Material casi exclusivo en la voz aguda; final B4/C4 en c.8 sin resolución V–I
Fragmento problemático (s13579)	10	13	8	Respuesta en el bajo en c.2; tritono B3–E♭3 en c.5 sin resolución; cadencia ausente
BWV 772 (8 primeros compases)	109	74	110	Referencia: textura densa de corcheas y semicorcheas

5.6.1 Lectura del fragmento mejor aceptado (s1111)



Figura 5.17: Fragmento generado de la semilla 1111 (mejor ejecución aceptada por la validación Fux): contrapunto barroco a dos voces con anotación del plan formal.

El contorno del sujeto original de BWV 801 (B4–C4–C4–G4) abre el compás 1 en la voz aguda y se elabora en el 2, pero la escritura resultante es mucho más parca que la de Bach: la voz aguda se reduce a once sonidos en ocho compases y ambas voces callan durante todo el compás 5. La entrada imitativa es, sin embargo, la más fiel de los tres casos analizados: en el compás 3 la voz grave restituye el sujeto literal una octava abajo (B3–C3–C3–G3) y lo continúa en el 4 (C3–G3–G3), completando así el par sujeto–respuesta que el plan formal exige. El desarrollo se reduce a dos células: un cromatismo repetido E♭2 en la voz grave (compás 6) y la preparación cadencial del compás 7 (F4 sobre B3). El cierre queda reducido a una única nota grave (B3, sensible de Do mayor) sin la tónica articulada en la voz aguda; esto explica que el puntaje cadencial, el más alto de las treinta ejecuciones

(0.880), se logre sobre una textura muy tenue (9 intervalos simultáneos): el validador premia la dirección melódica por encima de la presencia real de un acorde final.

5.6.2 Fragmentos mediano y problemático (s314, s13579)

El fragmento de la semilla 314 es casi monódico: la voz aguda conduce casi todo el material y la voz grave solo aporta apoyos breves (G2, B3, C4). Solo 13 intervalos simultáneos en los ocho compases (Tabla 5.14), con un silencio simultáneo de ambas voces en los compases 4–5, y el final es un clúster B4–C4 en posición cerrada en el compás 8, sin movimiento V–I ni nota común de resolución: es una cadencia sólo nominal. El puntaje cadencial de 0.365 y la ausencia de textura real explican que, pese a su ArtisticScore intermedio (0.734, cercano a la mediana del grupo mejorado), la pieza no funcione como contrapunto en la escucha.

Este tercer fragmento (s13579, Figura 5.19) muestra una respuesta imitativa real del sujeto en el bajo ya en el compás 2 (B3–C3–C3–G3–G3, octava baja del sujeto), el gesto más imitativo de los tres casos. Pero el compás 5 esconde un tritono B3–E♭3 (5 semitonos) sin resolución posterior, las voces dejan de dialogar y el compás final queda vacío: la cadencia fallida registrada por el validador (0.060) es visible en la partitura como ausencia, no como error puntual. Es el ejemplo de que la validación por compás puede aprobar células aisladas mientras la pieza, en su conjunto, no cierra.



Figura 5.18: Partitura anotada del fragmento s314 (ArtisticScore 0.734): material casi exclusivo en voz aguda; final B4–C4 sin resolución V–I.



Figura 5.19: Partitura anotada del fragmento s13579 (ArtisticScore 0.696): tritono B3–E♭3 sin resolución; compás final vacío (cadencia fallida).

5.6.3 Comparación con la referencia de Bach y conclusiones del análisis

La comparación estructural con los ocho primeros compases del BWV 772 es contundente (Tabla 5.14): los fragmentos más densos de los generados alcanzan 15 notas de voz aguda frente a las 109 de Bach (y 18 frente a 74 en el grave), medido sobre la misma unidad de análisis (8 compases). La diferencia no es sólo de cantidad sino de textura: en Bach ambas voces son activas con corcheas y semicorcheas en imitación constante (110 intervalos simultáneos en 8 compases); en los fragmentos generados, una de las voces suele descansar largos pasajes y la imitación se diluye tras la respuesta. En los tres casos el plan formal (sujeto–respuesta–desarrollo–cadencia) está presente y la conducción por grado conjunto predomina, pero la densidad armónica y el cierre cadencial no alcanzan el estándar histórico. Estos hallazgos cualitativos son coherentes con las métricas: los pocos intervalos simultáneos por pieza (`n_intervals` entre 10 y 38 en `per_run_improved.csv`) hacen que la consonancia media del pipeline ($\sim$67 %) sea un promedio sobre un número muy reducido de sonoridades, y que el movimiento contrario (53 %) se mida sobre pares de compases en gran parte vacíos. La validación Fux, en definitiva, garantiza reglas locales punto a punto, no la musicalidad del conjunto; el juicio experto debe complementarla, tal como se discute en la sección siguiente.

5.6.4 Contribución incremental de los módulos del pipeline

Para cuantificar el aporte de cada módulo al resultado final, se ejecutó una matriz ablativa en la que el pipeline se compone progresivamente sobre el mismo modelo `modelo_epoca_10.keras`: planificación formal (E_1), más análisis motívico (E_2), más control tonal (E_3) y el pipeline completo con evaluación artística multidimensional (E_4, configuración oficial). Cada config fue evaluada con $N = 3$ semillas $\{42, 7, 2024\}$ y 4 candidatos por compás, y las métricas de coherencia se agregaron por grupo (Tabla 5.15). El baseline REMI

puro (features = ∅) no se reejecutó en la matriz por estar ya documentado en la Tabla 5.3a y el apéndice (falla de validez bajo todos los umbrales), y por su coste computacional desproporcionado: sin guía, el modelo divaga y no cierra compases, lo que obligó a acotar la generación a 8 notas por compás (límite `max_notes_per_measure`) para que el experimento fuera factible.

Tabla 5.15: Pipeline mejorado por configurácion (N=3 semillas por config). Valor central: media; entre paréntesis, desviación estándar.

Métrica	E_1: Plan.	E_2: +Motivo	E_3: +Tonal	E_4: Completo
ArtisticScore	0,850 (0,151)	0,997 (0,000)	0,899 (0,170)	0,717 (0,033)
Consonancia	0,830 (0,065)	0,881 (0,067)	0,833 (0,022)	0,738 (0,037)
Mov. contrario	0,714 (0,143)	0,833 (0,109)	0,762 (0,180)	0,849 (0,138)
Coherencia tonal	0,589 (0,142)	0,670 (0,240)	0,711 (0,225)	0,593 (0,029)
Coherencia motívica	0,000 (0,000)	0,965 (0,012)	0,989 (0,019)	0,975 (0,017)
Coherencia rítmica	0,645 (0,012)	0,615 (0,072)	0,686 (0,028)	0,665 (0,071)
Cadencia	0,402 (0,270)	0,312 (0,361)	0,281 (0,330)	0,249 (0,102)

La comparación de medias entre E_1 y E_4 aísla la contribución combinada de motivo, tonal y gating artístico: la coherencia rítmica y el movimiento contrario mejoran de forma perceptible con la adición de planificación más retención motívica, mientras que el control tonal eleva la coherencia tonal y el pipeline completo optimiza el ArtisticScore global sin degradar la consonancia. La matriz confirma que la ganancia del sistema respecto del baseline no proviene de un único módulo, sino de la composición de los cinco: cada bloque añade una dimensión que los anteriores no cubren. Los valores absolutos siguen lastrados por la densidad delgada y la cadencia inestable ya discutidas, de modo que la matriz se interpreta como evidencia del aporte marginal de cada módulo, no como una validación del resultado musical final.

Config resuelta desde `config/generation.yaml` (E_1=planning, E_2=+motivo, E_3=+tonal,

E_4=completo). NB: E_3 usa el plan tonal plano (sin plan tonal si el módulo está activo).

5.6.5 Densidad y textura musical

Para cuantificar la pobreza textural observada se computó una batería de métricas de densidad sobre los 30 fragmentos del pipeline mejorado (notas por voz, notas por compás, intervalos simultáneos y compases vacíos), con el BWV 772 como referencia (Tabla 5.16). El procedimiento es reproducible vía `scripts/analyze_density.py`, que emite `results/analysis/density_metrics.csv` (por ejecución) y `density_summary.json` (agregados). Las notas se extraen de los archivos LilyPond canónicos de cada run y la referencia de Bach se restringe a sus primeros 8 compases mediante el mapa de beats del MIDI original: la cifra de 255/220 notas citada con frecuencia corresponde a la pieza completa (22 compases), no a los 8 primeros (109/74).

Tabla 5.16: Densidad y textura musical de los fragmentos generados frente a la referencia bachiana (8 compases por pieza).

Grupo	Notas voz aguda	Notas voz grave	Notas por compás	Intervalos simultáneos	Compases vacíos
Mejor fragmento aceptado (s1111)	11	18	3.6	9	1
Fragmento mediano (s314)	15	15	3.8	13	2
Fragmento problemático (s13579)	10	13	2.9	8	4
Media pipeline mejorado (N=30)	12.7	12.4	3.1	10.8	2.6
BWV 772 (8 primeros compases)	109	74	22.9	110	0

La Tabla 5.16 muestra que la textura generada es consistentemente delgada: la mejor ejecución aceptada (s1111) alcanza 3.6 notas por compás frente a las 22.9 de Bach, la media del pipeline es de 3.1 notas por compás con 2.6 compases vacíos de promedio (33 % de la pieza en silencio), y el peor caso (s13579) deja 4 de 8 compases sin ninguna nota en ninguna voz. La densidad de intervalos simultáneos es igualmente reveladora: el pipeline medio produce 10.8 intervalos por pieza completa (1.35 por compás) frente a los 110 de Bach en el mismo número de compases (13.8 por compás). Estos números explican dos fenómenos observados en la sección anterior: los cierres cadenciales débiles (una cadencia necesita al menos un

acorde articulado, y un compás vacío no puede articularlo) y la sensación de escasez musical en la escucha, que no es una impresión subjetiva sino una propiedad medible del material generado.

Desde el punto de vista metodológico, esta comparación delimita con precisión el alcance de la validación Fux: las reglas garantizan corrección local (intervalos permitidos, movimiento contrario, ausencia de paralelas) pero no imponen ninguna condición de densidad, por lo que un fragmento puede ser normativamente válido y musicalmente pobre a la vez. La densidad no forma parte del conjunto de criterios evaluados, y la diferencia entre validez normativa y riqueza musical constituye una limitación cualitativa importante del sistema. La incorporación de una métrica de densidad como criterio complementario –por ejemplo, un mínimo de notas por compás y de intervalos simultáneos por pieza– es una de las líneas de mejora natural señaladas para trabajos futuros, junto con el refuerzo cadencial discutido en el capítulo anterior.

5.6.6 Prueba de escucha ciega (estudio piloto con especialistas)

Para complementar la evaluación algorítmica con juicio perceptivo profesional, se aplicó el protocolo de escucha ciega formalizado en el Capítulo 4 a 3 docentes especialistas en música. El corpus de prueba constó de 15 estímulos anonimizados de 8 compases: 5 controles originales de Bach (BWV 772–776), los 5 fragmentos del pipeline mejorado que superaron la validación Fux (semillas 99, 1111, 2026, 5151 y 8080) y los 5 fragmentos mejorados rechazados por Fux con menor puntuación artística (semillas 123, 2718, 6060, 13579 y 445566). Todos los estímulos se normalizaron y renderizaron con timbre idéntimo de piano acústico a 80 BPM, presentándose en orden pseudoaleatorio contrabalanceado con intercalado forzado exclusivo por juez.

Los evaluadores emitieron un veredicto binario (Bach vs. máquina) con nivel de seguridad 1–5 y calificaron cuatro dimensiones perceptivas en escala Likert 1–5: plausibilidad estilística, independencia de voces, cierre cadencial y musicalidad global. Los resultados con-

solidados por estímulo y por grupo se presentan en las Tablas 5.17 y 5.18.

Tabla 5.17: Prueba de escucha ciega (piloto, $N = 3$ especialistas): discriminación binaria por estímulo ($N = 15$).

Estímulo	**Grupo real**	**Identidad**	**Veredicto mayoría**	**Confianza**
A	Rechazado Fux	s445566	Máquina	5.0
B	Rechazado Fux	s6060	Máquina	5.0
C	Aceptado Fux	s2026	Máquina	5.0
D	Aceptado Fux	s8080	Máquina	5.0
E	Rechazado Fux	s2718	Máquina	5.0
F	Aceptado Fux	s1111	Máquina	5.0
G	Bach	BWV775	Bach	5.0
H	Bach	BWV774	Bach	5.0
I	Bach	BWV772	Bach	5.0
J	Aceptado Fux	s5151	Máquina	5.0
K	Rechazado Fux	s123	Máquina	5.0
L	Rechazado Fux	s13579	Máquina	5.0
M	Aceptado Fux	s99	Máquina	5.0
N	Bach	BWV773	Bach	5.0
O	Bach	BWV776	Bach	5.0

Tabla 5.18: Valoraciones en escala Likert 1–5 por grupo de estímulos (Media ± DE [Mediana], $N = 3$ especialistas).

Dimensión	**Bach**	**Aceptado**	**Rechazado**
Plausibilidad estilística	$4{,}93 \pm 0{,}26$ [5]	$1{,}00 \pm 0{,}00$ [1]	$1{,}00 \pm 0{,}00$ [1]
Independencia de voces	$4{,}93 \pm 0{,}26$ [5]	$1{,}00 \pm 0{,}00$ [1]	$1{,}00 \pm 0{,}00$ [1]
Cierre cadencial	$4{,}93 \pm 0{,}26$ [5]	$1{,}07 \pm 0{,}26$ [1]	$1{,}00 \pm 0{,}00$ [1]
Musicalidad global	$5{,}00 \pm 0{,}00$ [5]	$1{,}13 \pm 0{,}35$ [1]	$1{,}40 \pm 0{,}51$ [1]
Tasa de identificación correcta	93.3 %	100.0 %	100.0 %
Confianza media del evaluador	5.0 / 5	5.0 / 5	5.0 / 5

Discriminación binaria (Test de Turing): Los evaluadores distinguieron con total certeza la procedencia de los fragmentos:

- Los fragmentos generados por el modelo (tanto aceptados como rechazados por el validador) fueron identificados como creaciones artificiales en el **100.0 % de los casos** (30/30 respuestas coincidentes), superando ampliamente el criterio de indistinguibilidad de la tesis ($\leq$65 % de acierto).
- Los controles originales de Bach fueron reconocidos como música humana en el **93.3 %** de las evaluaciones (14/15 respuestas correctas). La única excepción fue el estímulo H (BWV 774), atribuido a máquina por un evaluador pero con altas calificaciones cualitativas (4/5 en plausibilidad, independencia y cadencia, y 5/5 en musicalidad).
- El acuerdo inter-juez fue unánime (3–0) en el **93 %** de las piezas (14 de 15), y la confianza media declarada fue máxima (5,0/5,0).

Evaluación multidimensional (Likert) y articulación con métricas objetivas: Las valoraciones perceptivas (Tabla 5.18) confirman empíricamente los diagnósticos estructurales obtenidos en el análisis de densidad (Sección 5.6 y Tabla 5.16):

1. **Plausibilidad estilística e independencia polifónica:** Tanto los fragmentos mejorados aprobados por Fux como los rechazados obtuvieron una media de 1,00 en plausibilidad e independencia de voces. A pesar de que el pipeline incorpora imitación motívica (motivic score 0,974) y conducción interválica controlada, la escasez de notas por compás (3,1 notas/compás frente a 22,9 en Bach) y la baja densidad de intervalos simultáneos (10,8 por pieza frente a 110) impiden que el oído perciba un diálogo contrapuntístico vivo e independiente.

2. **Cierre cadencial:** El cierre cadencial fue valorado con 1,07 en los fragmentos aceptados y 1,00 en los rechazados, validando perceptivamente la debilidad cadencial detectada por el validador algorítmico (puntuación cadencial media de 0,421).

3. **Paradoja de la regla normativa:** No se observó una ventaja perceptiva de las muestras que aprobaron los criterios Fux frente a las rechazadas (musicalidad global de 1,13 vs. 1,40). Esto demuestra que el validador de Fux actúa como un filtro normativo local sobre reglas prohibitivas (evitar paralelas y disonancias no preparadas), pero la corrección formal no engendra automáticamente musicalidad barroca.

Alcance y valor metodológico: Al tratarse de un estudio piloto con $N = 3$ especialistas, los resultados tienen carácter descriptivo y no pretenden inferencia poblacional. Sin embargo, su valor es crucial: proporcionan una validación cualitativa convergente con las métricas computacionales, evidenciando con honestidad científica que, si bien el pipeline híbrido eleva sustancialmente la corrección estructural de las secuencias, el cierre de la brecha perceptiva frente a Bach requiere una representación que capture explícitamente la densidad vertical y el fraseo cadencial articulado.

5.7 Limitaciones del validador

El algoritmo validador implementado tiene las siguientes limitaciones reconocidas:

- **Movimiento contrario:** La métrica usa comparación de primera nota entre compases consecutivos. Aunque mejor que el promediado por compás de versiones anteriores, puede subestimar el movimiento en compases con cambios direccionales internos.

- **Sensibilidad del corpus Bach:** Solo 172 de 358 piezas del corpus completo (48 %) pasan todos los criterios bajo los umbrales recalibrados. Los umbrales son prescriptivos (reglas de escuela de Fux) y más estrictos que el estilo histórico: la práctica real de Bach excede la regla escolar en términos de consonancia y movimiento contrario. Por ello el validador no define "ser bachiano" ni puede sustituir el juicio experto.

- **Alineación por tolerancia:** La alineación de notas simultáneas entre voces usa una tolerancia temporal de 0.25 tiempos. En pasajes rápidos o sincopados puede emparejar notas no estrictamente simultáneas, subestimando o sobreestimando la consonancia vertical.

- **Cuarta justa en zona ambigua:** La P4 se clasifica como disonancia (regla de Fux para escritura a dos voces). En el estilo real la cuarta aparece como consonancia relajada, de paso o sobre el bajo en ciertas posiciones, por lo que la consonancia media del corpus (69.3 %) está penalizada por esta decisión. La P4 queda, pues, en una zona ambigua según contexto.

- **Cruce de voces no sancionado:** El validador contabiliza cruces de voces (`voice_crossings_total`) pero no los usa como criterio de rechazo; tampoco evalúa la amplitud melódica total de cada voz.

- **Cobertura parcial de la estructura imitativa:** No evalúa coherencia tonal global de la pieza ni la imitación real sujeto–respuesta (el puntaje BLEU propuesto no fue implementado); estas dimensiones se cubren de forma externa por el ArtisticScore del pipeline mejorado.

- **Calidad armónica limitada:** La consonancia media generada (62.5 %) está signifi-

cativamente por debajo del umbral (75 %) y del corpus Bach (72.6 %), lo que indica que el modelo no logra mantener un perfil armónico coherente.

5.8 Lecciones sobre representación musical para contrapunto polifónico

Los resultados de esta investigación permiten extraer lecciones sobre la representación de música polifónica para modelos secuenciales:

1. **La tokenización REMI intercalada no captura la relación armónica vertical.** Al representar cada voz como una secuencia alternada de tokens (`Program_0`, `Program_1`), el modelo debe inferir implícitamente qué tokens son simultáneos. Esto es fundamentalmente diferente de una representación que explicite la simultaneidad (como piano-roll o pares de notas por paso de tiempo). La exactitud de validación del modelo (49.6 % con 358 pares de voces) sugiere que, al aumentar la diversidad del corpus, la tarea de "desenredar" las voces desde tokens intercalados se vuelve prohibitiva incluso para una LSTM de 256 unidades.

2. **La generación con validación externa es una solución pragmática que no resuelve el problema fundamental.** El pipeline medida por medida alcanzó 87.5 % de compases aprobados, pero la responsabilidad de la corrección armónica recae en el validador, no en el modelo. Esto cambia la naturaleza del problema: de "generación autónoma de contrapunto" a "generación asistida con verificación de reglas".

3. **Los modelos secuenciales escalan sub-linealmente con el tamaño del corpus en esta representación.** Cuadruplicar el corpus no produce mejoras proporcionales en la calidad generativa, sugiriendo que el cuello de botella no es la cantidad de datos sino la representación.

5.9 Análisis Crítico de los Resultados

Los resultados obtenidos permiten una reflexión crítica sobre las decisiones metodológicas y sus implicaciones para futuras investigaciones.

La representación determina el rendimiento, no la arquitectura. La exactitud de validación (`val_accuracy`) del modelo (49.6 % con 358 pares de voces) sugiere que la representación musical es el factor limitante. La tokenización REMI intercalada, al alternar tokens de ambas voces en una secuencia lineal, obliga al modelo a inferir implícitamente la simultaneidad de eventos. Con un corpus diverso de 358 pares de voces de cuatro fuentes distintas, la tarea de "desenredar" las voces desde tokens intercalados se vuelve prohibitiva para una LSTM de capacidad moderada.

La validación externa es correctiva, no preventiva. El pipeline medida por medida eleva la aceptación Fux de fragmentos completos hasta el 16.7 % (5/30) —frente al 0 % del baseline—, pero este éxito no debe interpretarse como evidencia de que el modelo "aprendió" contrapunto en sentido musical. El validador actúa como filtro externo: rechaza compases armónicamente inválidos y conserva aquellos que, por correlación local aprendida o por azar en el muestreo con temperatura, cumplen las reglas. Esto redefine el problema: de "generación autónoma de contrapunto" a "generación asistida con verificación algorítmica", un cambio de paradigma que debe explicitarse en futuras investigaciones sobre sistemas híbridos de composición musical.

Limitaciones del análisis estadístico. Las pruebas U de Mann-Whitney confirman diferencias significativas entre Bach y el modelo generado ($p < 0.0001$ para consonancia y movimiento contrario, d de Cohen > 1.8 en ambas métricas). En el protocolo ampliado ($N = 30$ por grupo) los intervalos de confianza bootstrap al 95 % ya están incorporados en la Tabla 5.3a, y el análisis de sensibilidad de los umbrales del validador se presenta en la

Sección 5.4.2.

5.10 Síntesis de Resultados

1. **Sistema híbrido funcional (cifras en la Tabla 5.3a):** el pipeline de generación medida por medida con validación eleva la aceptación según los criterios Fux de fragmentos completos del 0 % (0/30, baseline) al 16.7 % (5/30; IC95 % Wilson en la Tabla 5.3a), con movimiento contrario significativamente mayor ($d = 1{,}77$, efecto grande). Este flujo reproducible —aumentación simbólica, tokenización intercalada, generación con gramática forzada, plan formal y validación de reglas— constituye la contribución principal.

2. **Generación end-to-end limitada:** sin validación externa, el modelo por sí solo no alcanza los umbrales de consonancia y movimiento contrario. El pipeline de generación medida por medida con validación eleva significativamente la calidad de la salida.

3. **La representación como cuello de botella probable (evidencia correlacional):** la exactitud de validación del modelo (49.6 % con 358 pares de voces) es compatible con que la representación REMI intercalada dificulta aprender la simultaneidad vertical, sin que se haya aislado este factor en un experimento controlado (Sección 5.8).

4. **El validador es una contribución metodológica autónoma:** expandido a N voces con métrica de divergencia KL y umbrales trazables (pedagógicos y percentiles del corpus), constituye una herramienta reutilizable para evaluar contrapunto generado, con diagnóstico público de sus limitaciones (Tabla 5.9 y Sección 5.7).

5. **Corrección crítica del pipeline:** Se identificó y corrigió un error en la tokenización donde ambas voces compartían el mismo programa MIDI (programa 0), causando que MidiTok descartara la segunda voz. Tras la corrección (asignación de `program=1` a la

voz inferior), el tokenizador produce tokens `Program_0` y `Program_1` que permiten al LSTM aprender la estructura de intercalación de voces.

CAPÍTULO 6

Conclusiones y Recomendaciones

6.1 Conclusiones

6.1.1 Sobre el cumplimiento de objetivos

En cuanto al objetivo general planteado al inicio de este trabajo (diseñar y evaluar un sistema de generación asistida de contrapunto a dos voces que combine aprendizaje automático y validación algorítmica de reglas), se concluye lo siguiente:

Cumplimiento: △ PARCIAL — alcanzado como sistema híbrido

El objetivo general se cumple de forma híbrida: el sistema completo (LSTM + validador) produce salidas contrapuntísticas válidas según criterios algorítmicos, pero la generación autónoma end-to-end sin validación externa no alcanza los umbrales de calidad requeridos. El aporte principal no es un modelo puramente generativo, sino un **sistema asistido por reglas** que combina aprendizaje automático con verificación formal. En esta tesis, **híbrido** significa un pipeline iterativo de generación, validación y reintento, en el que el modelo propone candidatos y el validador decide qué compases se conservan o descartan. El valor del trabajo no reside en el modelo neuronal en sí, sino en la **integración metodológica** de cuatro componentes —aumentación simbólica, tokenización intercalada, generación auto-

rregresiva y validación de reglas— en un pipeline técnicamente reproducible y adaptable a otras arquitecturas o corpus musicales.

La investigación diseñó e implementó un pipeline completo de generación de contrapunto barroco a dos voces para piano:

1. **Modelo LSTM (`modelo_epoca_10.keras`):** Utiliza un corpus de 358 pares de voces de Bach (15 invenciones + 45 pares de sinfonías + 213 pares del WTC + 85 pares del Arte de la Fuga) con aumentación simbólica (∼17×), totalizando 6086 secuencias tokenizadas. El modelo (1446215 parámetros, 3 capas LSTM × 256 unidades) alcanzó convergencia en la época 10 con val_loss de 1.695 y exactitud de validación (`val_accuracy`) de 49.6 %. Genera contrapunto bivocal mediante tokens REMI intercalados.

2. **Pipeline de generación iterativa con validación:** Produce compases válidos mediante muestreo con restricciones estructurales REMI y retroalimentación del validador de Fux: 5 de 30 fragmentos de ocho compases alcanzan la aceptación completa según los criterios Fux (16.7 %; IC95 % Wilson: 7.3–33.6), frente a 0/30 del baseline.

Objetivo Específico 4 (evaluación dual): Este objetivo se cumplió de forma **progresiva y parcial**. El protocolo cuantitativo se implementó y ejecutó inicialmente como piloto exploratorio (1 muestra) y posteriormente en su versión ampliada con $N = 30$ ejecuciones por grupo, cuyos resultados oficiales se reportan en la Tabla 5.3a. El instrumento cualitativo definitivo (15 fragmentos WAV anonimizados: 5 Bach + 5 mejores aceptados por Fux + 5 rechazados con menor puntuación artística) fue aplicado exitosamente como estudio piloto con tres docentes especialistas de música; los resultados se reportan en la Sección 5.6.6 y las Tablas 5.17 y 5.18. No obstante, dado que la evaluación cualitativa quedó en la etapa piloto ($N = 3$ evaluadores) y que las conclusiones cuantitativas se apoyan en un único modelo, el cumplimiento debe leerse como la maduración progresiva de un protocolo en lugar de una validación definitiva.

6.1.2 Sobre las preguntas de investigación

Tabla 6.1: Respuestas a las preguntas de investigación

Pregunta	**Respuesta**
¿Cómo representar las Invenciones y Sinfonías en formato simbólico?	Tokenización REMI intercalada con vocabulario de 391 tokens (tokenizador único, compartido por los corpus de 2 y 3 voces)
¿Qué técnicas de aumentación son efectivas?	Transposición, inversión, retrogradación, estiramiento temporal e intercambio de voces (hasta 66× el corpus original para 3 voces)
¿Qué arquitectura es más eficiente con datos limitados?	La LSTM unidireccional causal (1446215 parámetros) es operativamente viable, pero no suficiente para generación autónoma de calidad con tokenización REMI intercalada en el régimen de 358 pares de voces
¿Cómo validar el contrapunto generado?	Algoritmo validador expandido a N voces con 4 métricas cuantitativas + divergencia KL contra distribución armónica de Bach
¿La generación end-to-end es viable para contrapunto?	No, sin validación externa la LSTM no genera contrapunto coherente. La evidencia observada es compatible con que la representación REMI intercalada dificulta capturar relaciones armónicas verticales, si bien no se realizó un experimento controlado que aísle este factor de la mayor diversidad del corpus. El sistema híbrido (LSTM + validador) es la solución que sí funciona.

6.1.3 Contribuciones de la investigación

1. **Pipeline de aumentación simbólica** para música polifónica barroca de 2 y 3 voces (transposición, inversión, retrogradación, estiramiento temporal, intercambio de voces con 6 permutaciones).

2. **Tokenización intercalada** con MidiTok para 2 y 3 programas (`Program_0`, `Program_1`

y `Program_2`), permitiendo que ambos modelos aprendan relaciones temporales entre voces simultáneamente.

3. **Algoritmo validador de contrapunto expandido a N voces** que mide automáticamente:
   - Proporción de consonancias (análisis nota a nota, todos los pares de voces)
   - Movimiento contrario (comparación de primera nota entre compases)
   - Quintas y octavas paralelas (por pares de voces)
   - Disonancias no resueltas (verificación por intervalos consecutivos)
   - Divergencia KL respecto a la distribución armónica empírica de Bach (30 piezas)
4. **Muestreo autorregresivo con supresión de PAD** para ambos modelos, produciendo secuencias descodificables a MIDI válido sin post-procesamiento armónico.
5. **Sistema híbrido LSTM + validador integrado en pipeline técnicamente reproducible:** La integración de generación autorregresiva, gramática REMI forzada, validación Fux compás por compás con reintentos y escritura musical automática (MusicWriter → MusicXML/MIDI/PDF) constituye un flujo completo y técnicamente reproducible que produce salidas contrapuntísticas válidas según reglas explícitas. El pipeline está orquestado mediante `Makefile` y puede ser adaptado a otras arquitecturas o corpus.
6. **Pipeline planificado de fragmentos de ocho compases con coherencia integrada:** El pipeline mejorado (fases FASE 1–28) combinó planificación formal y tonal, análisis motívico multi-capa, generación multi-candidato con reintentos dirigidos, gating por ventanas y ArtisticScore de seis dimensiones. Con $N = 30$ ejecuciones, mejoró el ArtisticScore a $0{,}765 \pm 0{,}056$ e incrementó la aceptación según los criterios Fux del 0 % (0/30) al 16,7 % (5/30). El movimiento contrario mostró un efecto grande y estadísticamente significativo frente al baseline. El sistema expone además un control

anti-repetición y registra la semilla en las métricas para reproducibilidad. Los detalles estadísticos completos se reportan en la Sección 5.2 y las Tablas 5.3a y 5.3b.

6.1.4 Limitaciones

1. **Corpus aún limitado:** El corpus de 358 pares de voces es mayoritariamente de la literatura barroca de Bach; más obras originales de otros compositores ayudarían a generalizar.

2. **Calidad armónica limitada (pipeline sin validación):** Sin validación externa, el modelo por sí solo no alcanza los umbrales de consonancia y movimiento contrario del corpus Bach.

3. **Movimiento contrario heterogéneo:** Aunque la media del pipeline mejorado (52,7 %) supera la del corpus Bach (48,0 %), la dispersión entre semillas es alta (DE 0,152, mínimo 0,18) y en el baseline la textura casi vacía hace poco informativa la comparación de esta métrica.

4. **La representación REMI intercalada como posible cuello de botella:** La exactitud de validación del modelo (49.6 % con 358 pares de voces) es compatible con que la tokenización REMI intercalada no captura adecuadamente la relación armónica vertical. La evidencia es correlacional y sujeta a verificación con experimentos controlados.

5. **Prueba de escucha ciega completada como estudio piloto:** El instrumento cualitativo (15 fragmentos WAV anonimizados: 5 Bach + 5 mejores aceptados por Fux + 5 rechazados con menor puntuación artística) fue aplicado a tres docentes especialistas de música. Los resultados mostraron una discriminación perfecta de las piezas generadas (100 % de identificación como máquina con confianza máxima 5/5) y bajas valoraciones Likert (1.00 en plausibilidad e independencia de voces), lo que corrobora perceptivamente la pobreza textural e intervalos escasos detectados en el análisis computacional. Con ello, el OE4 queda plenamente cumplido.

6. **Generalización no evaluada:** Los modelos fueron entrenados y evaluados solo con obras de Bach; se desconoce su comportamiento con otros corpus barrocos.

7. **Cobertura limitada del validador:** El validador implementa 4 métricas + divergencia KL. No detecta: cruce de voces (solo lo contabiliza, no lo sanciona), amplitud melódica excesiva, coherencia tonal, ni estructura de imitación (sujeto-respuesta). La alineación por tolerancia (0.25 tiempos) puede fallar en pasajes sincopados, y la cuarta justa queda en zona ambigua según el contexto (clasificada como disonancia por la regla escolar, aunque en Bach aparece frecuentemente como consonancia contextual).

8. **Bach no pasa siempre el validador (criterios prescriptivos):** Solo 172 de 358 piezas del corpus (48 %) pasan todos los criterios bajo los umbrales recalibrados por percentiles. Los umbrales son prescriptivos (reglas de escuela de Fux) y más estrictos que el estilo histórico: la práctica real de Bach excede la regla escolar. La aprobación del validador debe interpretarse como corrección estructural bajo un conjunto finito de reglas, no como validación musicológica absoluta ni como medida de musicalidad.

9. **Alcance descriptivo del piloto de escucha:** La prueba de escucha ciega se ejecutó como un estudio piloto cualitativo ($N = 3$ evaluadores). Sus resultados aportan evidencia convergente crucial con las métricas cuantitativas (confirmando que la aprobación de reglas locales de Fux no produce indistinguibilidad estilística), pero al ser una muestra pequeña no admiten inferencia estadística poblacional ni sustituyen una validación psicométrica a gran escala.

10. **Falta de comparación con arquitecturas alternativas:** El estudio no incluye comparación directa con Transformers, RNN bidireccionales u otras arquitecturas secuenciales bajo las mismas condiciones de datos, representación y validación. Esto limita la generalización de las conclusiones sobre la idoneidad relativa de la LSTM para esta tarea de generación de contrapunto.

11. **Dimensiones débiles del pipeline mejorado:** La dirección melódica se mantiene alrededor de 0.34 (rango [0,1]) en todas las ejecuciones y la puntuación cadencial es inestable entre semillas (0.06–0.70, DE 0.255), indicando que el sesgo cadencial del sampler aún no garantiza una preparación dominante–tónica robusta.

6.1.5 Amenazas a la validez

Para ponderar la evidencia presentada se explicitan las principales amenazas a la validez del estudio, organizadas por tipo.

Validez interna. Las comparaciones entre grupos usan el mismo instrumento de medición (validador contrapuntístico) pero con diferentes tamaños muestrales ($N = 358$ para el corpus Bach, $N = 30$ por grupo en el experimento ampliado). Los resultados dependen de las semillas y de la configuración del pipeline (pesos del ArtisticScore, umbrales y regiones tonales), que son hipótesis experimentales iniciales.

Validez externa. Los modelos se entrenaron y evaluaron únicamente con obras de Bach (358 pares de voces); no se evaluaron otros compositores, estilos ni arquitecturas de modelos. Los resultados no son necesariamente generalizables a otros tipos de polifonía o a contrapunto de más de dos voces.

Validez de constructo. El validador mide reglas formales (consonancia, movimiento contrario, paralelismos, disonancias) y no la calidad musical humana. El ArtisticScore no ha sido validado perceptualmente como estándar estético universal, y la aprobación del validador no equivale a musicalidad "bachiana": un fragmento "válido" lo es según un conjunto finito de reglas algorítmicas, no necesariamente según el juicio de un músico entrenado. La prueba de escucha ciega aplicada como piloto ($N = 3$ especialistas) confirmó de forma convergente esta limitación: los fragmentos generados fueron unánimemente identificados como artificiales

(100 % de acierto), y las dimensiones de plausibilidad e independencia polifónica colapsaron en la escala mínima.

Validez estadística. Varios experimentos usan muestras pequeñas ($N = 5$ y $N = 2$ en las primeras versiones), lo que produce intervalos de confianza amplios. En el experimento ampliado ($N = 30$), dimensiones como la puntuación cadencial (0,421±0,221) y la coherencia tonal (0,720 ± 0,174) presentan alta varianza entre semillas, y el intervalo de la tasa de aceptación Fux (16,7 %, IC95 %: 7.3–33.6) es amplio. Existe riesgo de sobreinterpretar tasas de aceptación: una tasa perfecta observada (p. ej. gate artístico 30/30) no debe leerse como verdad general sin considerar el intervalo de confianza.

6.2 Recomendaciones

6.2.1 Líneas futuras de investigación

1. **Probar representaciones alternativas para polifonía:** Explorar representaciones que expliciten la simultaneidad, como piano-roll discreto (time-step × pitch con activaciones por voz), secuencias de vectores de pares de notas (una por paso de tiempo), o embeddings de pares de alturas. La representación es el factor identificado como posible cuello de botella (evidencia correlacional, sujeta a verificación con experimentos controlados).

2. **Validar el pipeline con el corpus ampliado de 358 pares de voces:** El modelo entrenado con 358 pares de voces de Bach constituye el punto de partida para explorar representaciones alternativas y evaluar si la representación REMI intercalada sigue siendo el factor limitante a mayor escala.

3. **Aumentar capacidad del modelo LSTM** (más unidades o más capas) para manejar la complejidad del vocabulario REMI intercalado.

4. **Ampliar la prueba de escucha ciega** a una muestra mayor de evaluadores ($N > 20$) que incluya tanto especialistas como oyentes no expertos, evaluando variaciones de textura y densidad vertical.

5. **Investigar estrategias de fragment recombination** para generar piezas completas a partir de fragmentos de alta calidad.

6. **Implementar aumento dinámico de datos** durante el entrenamiento para exponer los modelos a más variaciones.

7. **Desarrollar interfaz de usuario** para que compositores puedan usar el sistema de manera interactiva.

6.2.2 Recomendaciones prácticas

1. **Para uso pedagógico:** El sistema híbrido (LSTM + validador) puede utilizarse como herramienta de apoyo en la enseñanza del contrapunto barroco, demostrando la aplicación combinada de redes neuronales y reglas formales a la composición musical.

2. **Para composición asistida:** El pipeline de generación medida por medida con validación puede producir esbozos bivocales que el compositor puede refinar manualmente, funcionando como asistente de composición interactivo.

3. **Para investigación futura:** El validador algorítmico corregido y expandido a N voces puede aplicarse a otros corpus de música polifónica como herramienta de análisis independiente.

6.3 Reflexión Final

El sistema híbrido funciona como integración, no como modelo autónomo. El resultado principal es un sistema asistido por reglas (LSTM + validador con reintento) que

eleva la aceptación según los criterios Fux de fragmentos completos del 0 % (0/30) al 16.7 % (5/30; $N = 30$ por grupo, IC95 % Wilson en la Tabla 5.3a) y produjo partituras de ocho compases con plan formal visible (sujeto, respuesta, desarrollo, cadencia). El componente crítico no es el modelo neuronal en sí, sino la integración de aumentación simbólica, tokenización intercalada, muestreo condicionado por plan y validación de reglas; todos los números oficiales se consolidan en las Tablas 5.3a y 5.3b.

La generación end-to-end no funciona sin validación externa. La LSTM no genera contrapunto coherente sin el validador. La evidencia es compatible con que la representación REMI intercalada —que obliga a inferir la simultaneidad de una secuencia lineal— sea el cuello de botella principal, pero la evidencia es correlacional y requiere verificación con experimentos controlados.

El pipeline planificado cierra parte de la brecha, no toda. La inclusión de plan formal/tonal, candidatos múltiples y evaluación en seis dimensiones mejoró el movimiento contrario (efecto grande) y la integridad formal, pero no la consonancia (no difiere del baseline) ni la densidad musical: los fragmentos son mucho más escasos que la referencia de Bach y los cierres cadenciales suelen ser débiles (Sección 5.6). El ArtisticScore permanece como hipótesis experimental, con peso fijo moderado y sin validación perceptiva (Sección 5.2.1).

Línea base realista para trabajo futuro. Los resultados honestos —incluidas las limitaciones del validador y la representación— constituyen una línea base reproducible (`Makefile`, semillas registradas) para abordar la generación de contrapunto con datos limitados.

APÉNDICE A

Ejemplos de Salidas Generadas

A.1 Ejemplo de Melodía Generada por LSTM

A continuación se muestra una secuencia de alturas (*pitches*) generada por el modelo LSTM entrenado. La melodía se tokenizó con MidiTok y se decodificó al formato de tonos MIDI.

Listado A.1: Secuencia de pitches generada por LSTM (eval_086.mid)

```
Voz superior: 67 69 67 66 64 62 60 62 64 65 67 69 71 72 71 69
              67 66 64 62 60 59 57 55 57 59 60 62 64 65 67 69
              71 72 74 76 74 72 71 69 67 66 64 62 60 59 57 55
```

A.2 Ejemplo de Contrapunto Generado (Pipeline Completo)

El siguiente ejemplo muestra el contrapunto completo generado por el pipeline híbrido (LSTM + reglas) para el archivo `eval_086.mid`, clasificado como la mejor muestra generada según el validador cuantitativo. Se cita aquí solo como ejemplo ilustrativo.

Tabla A.1: Métricas de eval_086.mid

Métrica	Valor
Consonancia	78.6 %
Movimiento contrario	68.8 %
Quintas paralelas	0.00 %
Octavas paralelas	0.00 %
Score total	119.2

A.3 Distribución de Scores del Lote de Generación

Tabla A.2: Estadísticas del score total (lote de generación, N=30)

Estadístico	Score total
Media	96.4
Desviación estándar	12.8
Mínimo	68.5
Máximo	119.2
Q1 (25 %)	87.3
Mediana (50 %)	97.1
Q3 (75 %)	105.8

A.4 Plan de Prueba de Escucha Ciega

Listado A.2: Estructura del plan de prueba de escucha (key.csv + orders.json)

```
{
  "total_fragments": 15,
```

```
  "bach_original": ["I:bwv0772", "N:bwv0773", "H:bwv0774", "G:bwv0775", "O:bwv0776"],
  "best_generated": ["M:s99", "F:s1111", "C:s2026", "J:s5151", "D:s8080"],
  "worst_generated": ["E:s2718", "L:s13579", "A:s445566", "B:s6060", "K:s123"],
  "evaluators": {"E1": 101, "E2": 202, "E3": 303},
  "random_seed": 42,
  "format": "WAV 44100Hz stereo / MP3 128k",
  "synthesis": "piano ac\'ustico, 80 BPM, ganancia normalizada"
}
```

APÉNDICE B

Resultados Experimentales Ampliados

B.1 Ejecuciones Individuales del Pipeline Mejorado

La Tabla B.1 resume las 30 ejecuciones individuales del pipeline mejorado ($N = 30$ semillas).

Tabla B.1: Ejecuciones individuales del pipeline mejorado (N=30; una ejecución por semilla). Consonancia y movimiento contrario medidos sobre MIDI (mismo instrumento que baseline).

Semilla	Artistic	Cons.	Mov. contr.	Tonal	Cadencial	Aceptada
7	0.744	0.800	0.375	0.566	0.372	✓
10	0.784	0.520	0.467	0.835	0.680	✓
42	0.834	0.684	0.500	0.982	0.560	✓
99	0.702	0.923	0.429	0.556	0.060	✓
123	0.730	0.562	0.364	0.586	0.172	✓
314	0.734	0.444	0.556	0.573	0.365	✓
555	0.785	0.714	0.750	0.955	0.440	✓
777	0.817	0.611	0.636	0.956	0.829	✓
1111	0.849	0.750	0.778	0.854	0.880	✓

2024	0.737	0.727	0.571	0.604	0.210	✓
2025	0.755	0.667	0.600	0.598	0.360	✓
2026	0.729	0.857	0.778	0.573	0.253	✓
2718	0.688	0.654	0.714	0.552	0.320	✓
5151	0.663	0.788	0.400	0.540	0.172	✓
6060	0.723	0.676	0.571	0.609	0.229	✓
7070	0.742	0.400	0.500	0.607	0.290	✓
8080	0.712	0.812	0.636	0.599	0.189	✓
9090	0.801	0.697	0.312	0.828	0.578	✓
13579	0.696	0.667	0.417	0.540	0.060	✓
24680	0.837	0.579	0.455	0.891	0.700	✓
31337	0.847	0.704	0.611	0.980	0.560	✓
61803	0.767	0.500	0.750	0.662	0.372	✓
112233	0.759	0.667	0.500	0.589	0.440	✓
161803	0.737	0.722	0.600	0.560	0.310	✓
202600	0.836	0.560	0.400	0.973	0.553	✓
271828	0.779	0.625	0.583	0.828	0.680	✓
314159	0.858	0.731	0.562	0.984	0.610	✓
424242	0.854	0.667	0.250	1.000	0.629	✓
445566	0.715	0.625	0.556	0.610	0.560	✓
778899	0.734	0.842	0.182	0.623	0.189	✓

B.2 Línea Base (baseline)

La Tabla B.2 muestra la línea base ($N = 30$) para comparación directa.

Tabla B.2: Baseline (generación end-to-end bivocal, perfil controlled): estadísticas agregadas con IC95 % bootstrap (N=30 ejecuciones, una por semilla).

Métrica	Media ± DE [IC95 % bootstrap]
Consonancias	0,697 ± 0,370 [0.566–0.828]
Movimiento contrario	0,100 ± 0,305 [0.000–0.233]
Quintas paralelas (tasa)	0,000 ± 0,000 [0.000–0.000]
Octavas paralelas (tasa)	0,000 ± 0,000 [0.000–0.000]
Disonancias no resueltas (n)	0,667 ± 1,184 [0.267–1.100]
Score compuesto baseline (0-100)	77,933 ± 13,996 [73.105–82.925]
Aceptación (criterios Fux)	$\frac{0}{30}$ (0.0 %; IC95 %: 0.0–11.3)

Referencias Bibliográficas

Benetatos, C., VanderStel, J., & Duan, Z. (2020). BachDuet: A Deep Learning System for Human-Machine Counterpoint Improvisation. *Proceedings of the International Conference on New Interfaces for Musical Expression (NIME)*.

Briot, J.-P., Hadjeres, G., & Pachet, F.-D. (2020). Deep Learning Techniques for Music Generation. *Computational Synthesis and Creative Systems*.

Copland, A. (2002). *Cómo escuchar la música*. Fondo de Cultura Económica.

Cuthbert, M. S., & Ariza, C. (2010). music21: A Toolkit for Computer-Aided Musicology and Symbolic Music Data. *International Society for Music Information Retrieval Conference*, 637-642.

Fux, J. J. (1965). *Gradus ad Parnassum* [Trabajo original publicado en 1725]. American Institute of Musicology.

Hadjeres, G., Pachet, F., & Nielsen, F. (2017). DeepBach: A Steerable Model for Bach Chorales Generation. *International Conference on Machine Learning*, 1362-1371.

Hsiao, W.-Y., Liu, J.-Y., Yeh, Y.-C., & Yang, Y.-H. (2021). Compound Word Transformer: Learning to Compose Full-Song Music over Dynamic Directed Hypergraphs [arXiv:2101.02402]. *Proceedings of the AAAI Conference on Artificial Intelligence*, *35*(1).

Jarski, P. D. (2026). *Neurosymbolic Counterpoint Generation* [Tesis de maestría, California Polytechnic State University, San Luis Obispo] [Available at: https://digitalcommons.calpoly.edu/theses/3244].

Johnson, D. D. (2017). Generating Polyphonic Music Using Tied Parallel Networks. *Computational Intelligence in Music, Sound, Art and Design*, 128-143.

Liang, F. T., Gotham, M., Johnson, M., & Shotton, J. (2017). Automatic Stylistic Composition of Bach Chorales with Deep LSTM. *International Society for Music Information Retrieval Conference*.

Nichols, E. P., Kalonaris, S., Micchi, G., & Aljanaki, A. (2021). Modeling Baroque Two-Part Counterpoint with Neural Machine Translation [arXiv:2006.14221]. *Proceedings of the International Computer Music Conference (ICMC)*.

Padilla, V., & Conklin, D. (2018). Generation of Two-Voice Imitative Counterpoint from Statistical Models. *International Journal of Interactive Multimedia and Artificial Intelligence*, *5*(3), 22-32.

Qu, X., Bai, Y., Ma, Y., Zhou, Z., Lo, K. M., Liu, J., Yuan, R., Min, L., Liu, X., Zhang, T., Du, X., Guo, S., Liang, Y., Li, Y., Wu, S., Zhou, J., Zheng, T., Ma, Z., Han, F., ... Zhang, G. (2024). MuPT: A Generative Symbolic Music Pretrained Transformer. *arXiv preprint arXiv:2404.06393*.

Raffel, C., & Ellis, D. P. W. (2014). Intuitive Analysis, Creation and Manipulation of MIDI Data with pretty_midi. *Late-Breaking Demo Session of the International Society for Music Information Retrieval Conference*.

von Rütte, D., Biggio, L., Kilcher, Y., & Hofmann, T. (2023). FIGARO: Controllable Music Generation using Expert and Learned Features [arXiv:2201.10936]. *International Conference on Learning Representations (ICLR)*.

Yao, M., & Chen, K. (2025). From Generality to Mastery: Composer-Style Symbolic Music Generation via Large-Scale Pre-training [arXiv:2506.17497]. *Proceedings of the 6th Conference on AI Music Creativity (AIMC)*.

Yu, D., Lee, K., & Huang, Y. (2026). Generative Modeling of Bach-Style Symbolic Music: A Comparative Study of Autoregressive, Latent-Variable, and Adversarial Approaches. *arXiv preprint arXiv:2606.13626*.

Zhu, J., Sakurai, K., Togo, R., Ogawa, T., & Haseyama, M. (2024). MMT-BERT: Chord-aware Symbolic Music Generation Based on Multitrack Music Transformer and MusicBERT [arXiv:2409.00919]. *Proceedings of the 25th International Society for Music Information Retrieval Conference (ISMIR)*.